



Uncertainty-aware large language ...
PDF

この論文の内容を全て確認した上で、詳しく解説してください。
特に、

- 診断基準に基づいて電子カルテ内の診断根拠を抽出する
- 根拠の一部をマスクして evidence-incomplete note を合成する
- 現在の情報が確信を持った診断に十分かを判定する
- 不十分な場合には診断不確実性とその理由を説明する
- マスク後も潜在的な正解診断自体は変わらないことを専門家が確認する

について、どのようにデザインしたのか、数理的にどう表現しているかを示してください。

表示を減らす ^



19m 6s考えました >

1. 論文の中心的な発想

この論文は、電子カルテから最も可能性の高い診断を出すだけでなく、その診断を確定的に述べるだけの根拠がカルテ内にそろっているかを判定し、不足している場合には「何が足りないため不確実なのか」を説明するLLMとして、ConfIDxを提案しています。本文13ページに加え、公開されているSupplementary Notes 1-13も確認しました。論文は *Uncertainty-aware large language models for explainable disease diagnosis* と題されています。 Uncertainty-aware large languag...

最も重要なのは、この論文における **diagnostic uncertainty** が、一般的な意味での「モデルの予測確率が低い」「生成結果が揺れる」といった不確実性ではないことです。

ここで扱われているのは、

予測された疾患の診断基準と照合したとき、カルテ内の証拠が十分にそろっていないという **evidence uncertainty**

です。

したがってConfIDxは、単なる確信度推定モデルではありません。次の4つを別々のサブタスクとして学習します。

1. 疾患診断
2. 診断根拠の説明
3. 診断不確実性の認識
4. 診断不確実性の理由の説明

著者らは、「診断基準が満たされていない原因が、決定的症状の欠如、曖昧な臨床所見、決定的でない検査結果などの証拠不足である場合」に診断不確実性が生じる、と定義しています。

Uncertainty-aware large languag...

2. 研究全体の設計

2.1 使用データ

主なデータは次の3つです。

- **MIMIC**：MIMIC-IVから作成した学習・検証・テスト用データ
- **MIMIC-U**：学習時に全く見せていない6疾患による外部的な疾患タイプ検証
- **UMN-CDR**：University of Minnesotaの別施設EHRによる施設外検証

対象領域は、内分泌、循環器、肝臓の3領域です。

データセット	ノート数	疾患数	Evidence-incomplete
MIMIC	24,367	12	12,183
MIMIC-U	409	6	204
UMN-CDR	908	11	454

MIMICは17,057件を学習、2,436件を検証、4,874件をテストに使用しています。MIMIC-Uには学習から完全に除外した疾患が含まれ、UMN-CDRは記載様式や施設が異なるデータに対する一般化性能の評価です。

 Uncertainty-aware large languag... +1

疾患選択は、おおむね次の条件で行われました。

1. ICD-10-CMに基づいて対象診療領域の疾患を抽出する
2. 明確な診断基準がない疾患を除く
3. 診断基準が2項目未満の疾患を除く
4. 対象ノートの主診断として出現しない疾患を除く

最終的に18疾患が選ばれ、そのうち12疾患をMIMICに、6疾患を未知疾患用のMIMIC-Uに割り当てています。 Uncertainty-aware large languag...

MIMIC-Uの6疾患は、急性心膜炎、自己免疫性肝炎、リウマチ性僧帽弁狭窄、二次性高血圧、原発性胆汁性胆管炎、副甲状腺機能低下症です。 Springer Nature

2.2 正解診断をカルテ本文から隠す前処理

元の退院時サマリーには、疾患名そのもの、治療薬、退院時診断などが書かれているため、そのまま入力すると診断ラベルのリークが起こります。

そこで著者らは、正解診断をメタデータとして保持しながら、モデルに渡すノートから以下を削除しました。

- 現在の診断名
- 対象疾患を直接示す表現
- 該当する場合の薬剤情報
- 退院時の診断・処置に関する情報

補足資料によれば、この処理は、

1. LLMによるセクション単位の削除
2. 疾患名、略称、残存語を対象としたルールベース削除
3. 3つのLLMによる診断語残存の検証
4. 各データセット100件の人手確認

という多段階処理です。人手確認したノートでは対象診断名が残っていなかったと報告されています。

 Uncertainty-aware large languag...  Springer Nature +1

数理的には、元ノートを x_i^{raw} 、正解診断を y_i とすると、診断リーク除去関数 ρ により、

$$x_i = \rho(x_i^{\text{raw}}; y_i)$$

と表せます。

ここで、

- y_i : データベース上の正解診断として保持される
- x_i : 診断名などを削除し、モデルに入力されるカルテ

です。

3. 診断基準に基づいてカルテ内の診断根拠を抽出する方法

3.1 診断基準の準備

著者らは、American Diabetes Association、American Heart Associationなどの専門学会・診療ガイドラインから、各疾患の診断基準を手作業で収集しました。これを、カルテ内の情報が十分かどうかを判断するための代理的なゴールドスタンダードとして用いています。  Uncertainty-aware large languag...

疾患 y の診断基準集合を、

$$C_y = \{c_{y1}, c_{y2}, \dots, c_{ym_y}\}$$

と定義できます。

例えば、ある疾患について、

$$C_y = \{\text{症状A, 検査結果B, 既往歴C}\}$$

のように複数の基準項目が存在します。

3.2 4つのEvidence Extractor Agent

補足資料では、診断根拠の抽出に次のマルチエージェント構成を使用しています。

- Evidence extractor agent：4体
- Examiner agent：1体
- Generator agent：1体

4つのextractorのうち、

- 2体はLLaMA-3.1-70B
- 2体はDeepSeek-R1-Distill-Llama-70B

を使用しました。

各extractorは、ノート全体を一括して自由に要約するのではなく、**診断基準を1項目ずつ順番に走査し、その基準を支持する記述をノートから抽出**します。1つの基準を支持する情報が複数文に分散している場合には、それらを連結できます。抽出時のtemperatureは0.1とされ、出力の変動を抑えています。

 Springer Nature +1

患者 i 、基準項目 j 、extractor agent a の出力を、

$$E_{ij}^{(a)} = \text{Extractor}_a(x_i, y_i, c_{yij}), \quad a = 1, \dots, 4$$

と表せます。

$E_{ij}^{(a)}$ は、基準 c_{yij} を支持するとagentが判断したカルテ内の文またはスパンです。

3.3 Examiner Agentによる統合

4つのextractorが異なる根拠を抽出する可能性があるため、Examiner agentが結果を統合します。

$$E_{ij} = \text{Examiner} \left(x_i, y_i, c_{yij}, E_{ij}^{(1)}, E_{ij}^{(2)}, E_{ij}^{(3)}, E_{ij}^{(4)} \right)$$

Examinerは、

- 抽出された記述が実際にその基準を支持するか
- 必要な構成要素がすべて存在するか
- 複数agentの出力をどのように統合するか

を判定します。

基準 j がノート中で満たされているかを、

$$s_{ij} = \begin{cases} 1, & E_{ij} \text{が基準 } c_{y_{ij}} \text{を十分に支持する} \\ 0, & \text{支持情報がない、または不十分} \end{cases}$$

と表せます。

このように、本研究の「診断説明」はモデルが新しく医学的説明を作文するというより、原則として、**診断基準**と対応するカルテ内の根拠記述を抽出する**evidence grounding**タスクです。

補足資料の診断説明用プロンプトでも、ノート内の正確な表現を使用し、ノートに存在しない証拠を生成しないよう指示されています。  Springer Nature

4. Evidence-complete noteを作る方法

ここは本文だけでは分かりにくい重要な点です。

著者らは、単に「もともと診断根拠がすべてそろっているノート」だけをcomplete群にしているわけではありません。

補足資料のannotation pipelineでは、Examinerが診断基準の一部が不足していると判断した場合、Generator agentがその不足項目に対応する症状・検査所見などを生成し、ノートを補完します。Generatorのtemperatureは1で、より多様な表現を生成させています。  Springer Nature +1

不足基準の集合を、

$$J_i^{\text{miss}} = \{j : s_{ij} = 0\}$$

とします。

Generatorが不足基準に対して生成する記述を、

$$\tilde{e}_{ij} = G(x_i, y_i, c_{y_{ij}}), \quad j \in J_i^{\text{miss}}$$

とすると、evidence-complete noteは、

$$x_i^+ = x_i \oplus \{\tilde{e}_{ij} : j \in J_i^{\text{miss}}\}$$

と表せます。

$\oplus$ は、元のノートに生成した臨床記述を適切な位置または形式で加える操作です。

したがって、本論文におけるevidence-complete noteには、次の2種類が混在し得ます。

1. 元のカルテだけで基準がそろっていたノート
2. 不足していた基準の記述をGeneratorが補ってcompleteにしたノート

これは本研究を理解する上で重要です。完全ノートは、必ずしも「手を加えていない現実のカルテ」ではなく、**診断基準上の完全性を保証するために合成された可能性があるノート**です。

5. 根拠の一部をマスクしてevidence-incomplete noteを合成する方法

5.1 基本的な処理

evidence-complete note x_i^+ から、診断基準に対応する証拠の一部を選んでマスクし、evidence-incomplete noteを作成します。

マスク対象となる基準項目集合を、

$$M_i \subseteq \{1, \dots, m_{y_i}\}$$

とします。

その基準を支持するカルテ内スパンを除去するマスク関数を $\mathcal{M}$ とすると、

$$x_i^- = \mathcal{M} \left(x_i^+; \bigcup_{j \in M_i} E_{ij} \right)$$

となります。

- x_i^+ ：証拠がそろったcomplete note
- x_i^- ：一部の証拠を除いたincomplete note
- M_i ：意図的に欠落させた診断基準項目
- E_{ij} ：その項目を支持するカルテ内記述

本文では、「all relevant descriptions」を診断根拠としてアノテーションし、その一部をmaskすることで evidence-incomplete note を作成したと説明しています。データ全体ではcompleteとincompleteを1対1にしています。 [🔗 Uncertainty-aware large languag...](#)

5.2 マスクの目的

この操作は、患者の疾患そのものを変更するためのものではありません。

変更するのは、

患者の臨床状態

ではなく、

モデルから観測可能な診断根拠

です。

データラベルとしては、

$$(y_i, u_i) : (y_i, 0) \longrightarrow (y_i, 1)$$

という変換になります。

ここで、

- y_i ：正解診断。マスク前後で不変
- $u_i = 0$ ：十分な証拠あり
- $u_i = 1$ ：証拠不足による診断不確実性あり

です。

つまり、診断ラベルを固定したまま、evidence sufficiency labelだけを反転させるcounterfactual data augmentationと理解できます。

5.3 論文に記載されていない部分

一方、再現性の観点から重要な次の事項は、本文・補足資料でも十分に明記されていません。

- 1ノートにつき何個の基準をマスクしたか
- マスク数の分布
- ランダムに選んだのか、臨床的重要度で選んだのか
- 単語、フレーズ、文、段落のどの粒度で削除したか
- 削除、空欄化、プレースホルダー挿入のどれを用いたか
- 同じ基準を支持する重複記述が複数ある場合に、すべて除いたか
- complete版とincomplete版をデータ分割時に同一グループとして扱ったか
- masking後に不採用となった件数や割合

したがって、本論文は「診断根拠を制御して削除する」という研究デザインを示していますが、そのmasking operator自体は、論文情報だけでは完全には再実装できません。

6. 現在の情報が確信を持った診断に十分かを判定する方法

6.1 本研究の判定ロジック

疾患 y_i の各診断基準について、ノート内に対応する証拠が存在するかを表すベクトルを、

$$\mathbf{s}_i = (s_{i1}, s_{i2}, \dots, s_{im_{y_i}})$$

とします。

一般的には、診断基準の充足判定は、

$$q_i = g_{y_i}(\mathbf{s}_i)$$

と書けます。

g_{y_i} は疾患固有の診断規則です。例えば、

- 全項目必須：AND
- 複数項目のうちいずれか：OR
- k 項目中 r 項目以上
- 検査値が閾値を超える
- Aかつ、BまたはC

などが考えられます。

ただし、補足資料の実際のuncertainty recognition promptは、概ね、

ノートが診断基準のすべてのentriesを満たしているか

を判定させています。  Springer Nature

したがって、論文の運用を単純化すると、

$$q_i = \prod_{j=1}^{m_{y_i}} s_{ij} = \begin{cases} 1, & \forall j, s_{ij} = 1 \\ 0, & \exists j, s_{ij} = 0 \end{cases}$$

です。

診断不確実性ラベルは、

$$u_i = 1 - q_i$$

となります。

- $q_i = 1, u_i = 0$: sufficient information / confident diagnosis
- $q_i = 0, u_i = 1$: incomplete evidence / diagnostic uncertainty

6.2 「診断が正しいか」と「診断根拠が十分か」は別タスク

この研究では、次を分けて扱っています。

$$\hat{y}_i = f_D(x_i)$$

は、最も可能性の高い診断の予測です。

一方、

$$\hat{u}_i = f_U(x_i, \hat{y}_i)$$

は、その予測診断について証拠が十分かどうかの判定です。

したがって、ConfiDxは、

診断は急性肝不全が最も可能性が高い。しかし、肝硬変の既往がないことを確認できる情報がないため、確定診断には不十分である

という出力が可能です。

論文のFigure 6、8ページの症例では、正解診断は急性肝不全ですが、「prior history of cirrhosisがないこと」を示す情報が欠けているため、診断不確実性ありとしています。ConfiDxはこの不足を正しく特定しました。

反対に急性心膜炎のcomplete例では、胸痛、少量の心嚢液、ST上昇、心膜摩擦音などを根拠として、十分な情報ありと判定しています。

6.3 これは確率的confidence calibrationではない

この判定には、例えば、

$$P(Y = y \mid X = x) = 0.61$$

や、

$$\max_y P(Y = y \mid X = x) < \tau$$

のような確率閾値は使われていません。

また、次のような一般的なLLM不確実性推定でもありません。

- token probability
- entropy
- self-consistency
- confidence elicitation
- calibration error
- abstention probability

本研究は、

$$\text{criteria completeness} \longrightarrow \text{binary evidence uncertainty}$$

というルールに基づく教師あり分類です。

著者ら自身も、LLMの自己申告confidenceは事実正確性と一致しない可能性があるため、診断基準への適合性を不確実性の根拠にすべきだと論じています。

7. 不十分な場合に診断不確実性と理由を説明する方法

マスク後のノート x_i^- について、満たされていない基準集合を、

$$R_i = \{c_{y_{ij}} : s_{ij}(x_i^-) = 0\}$$

とします。

この R_i がuncertainty explanationの正解になります。

例えば、

$$R_i = \{\text{No prior history of cirrhosis}\}$$

であれば、説明は、

肝硬変の既往がないことを示す証拠がないため、確定診断には情報が不十分である

となります。

補足資料のプロンプトでは、uncertainty explanationについて、

- ノートに満たされていない診断基準のみを列挙する
- 満たされている基準を不足理由として挙げない
- 一般的な医学知識を自由生成するのではなく、診断基準との不一致を示す

したがってConfiDxの説明は、概念的には、

$$\hat{R}_i = f_R(x_i, \hat{y}_i, \hat{E}_i)$$

です。

ここで、

- $\hat{y}_i$ ：予測診断
- $\hat{E}_i$ ：カルテから抽出した診断支持根拠
- $\hat{R}_i$ ：満たされていない診断基準

です。

7.1 診断説明と不確実性説明の違い

この論文では、2種類の説明を明確に区別しています。

診断説明

$$E_i^{\text{support}} = \{E_{ij} : s_{ij} = 1\}$$

すなわち、

カルテ内のどの記述が診断を支持しているか

です。

不確実性説明

$$R_i^{\text{missing}} = \{c_{y_{ij}} : s_{ij} = 0\}$$

すなわち、

診断基準のうち、何がカルテ内に記録されていないか

です。

この二分は本研究の重要な貢献です。

単に「確信がありません」と出すのではなく、

observed supporting evidence + unmet criteria

を同時に出力します。

ただし、uncertainty explanationは基本的には不足基準の列挙であり、広範な鑑別診断、追加検査の期待情報価値、次に患者へ尋ねるべき具体的質問までを最適化するタスクではありません。

8. マスク後も潜在的な正解診断が変わらないことの専門家確認

本文では、domain expertsがmodified notesを確認し、maskingによって診断が変化していないことを保証したと記載しています。  Uncertainty-aware large languag...

この操作は、数理的にはexpert validation gateとして表せます。

$$V_i = V_{\text{expert}}(x_i^+, x_i^-, y_i)$$

$$V_i = \begin{cases} 1, & \text{マスク後も正解診断 } y_i \text{ が維持される} \\ 0, & \text{マスクによって診断自体が変化した} \end{cases}$$

最終データに残すのは、

$$\mathcal{D}^- = \{(x_i^-, y_i, u_i = 1, R_i) : V_i = 1\}$$

です。

これによって、データ生成の意図は、

$$Y_i^+ = Y_i^- = y_i$$

を維持しながら、

$$U_i^+ = 0, \quad U_i^- = 1$$

とすることになります。

つまり、

- 患者の潜在的疾患は同じ
- 最も可能性の高い診断も原則として同じ
- ただし、その診断を確定的に支持する文書上の根拠は不足する

という状態を作っています。

8.1 「診断が変わらない」の解釈には注意が必要

専門家確認が保証すべきものには、少なくとも2つのレベルがあります。

レベルA：潜在的な疾患ラベルが変わらない

$$Y_i^- = Y_i^+ = y_i$$

患者は実際には同じ疾患であり、カルテの一部を削除しただけなので疾患自体は変わらない、という意味です。

レベルB：マスク後も同じ疾患が最も可能性の高い

$$\arg \max_y P(y \mid x_i^-) = y_i$$

ただし、確定に必要な証拠が不足している、という意味です。

論文の目的からはレベルBまで確認していることが望ましいですが、本文には、

- 専門家がどの質問に回答したか
- 元ノートとマスク後ノートの両方を見たか
- 正解診断を提示されたか
- 診断基準を提示されたか
- 何人の専門家が確認したか
- 意見不一致をどう処理したか
- 何件が不採用になったか

が記載されていません。

したがって、論文から確実に言えるのは、

domain expertsがマスク後のノートを確認し、診断を変化させないと判断した

というところまでです。「診断不変性」をどのような判定基準で運用したかは再現できません。

8.2 IAA評価とは別物

補足資料では、LLMによるアノテーションと人手アノテーションの一致度も評価されています。

報告されたCohen's κ は、

- uncertainty label : MIMIC 0.93、UMN-CDR 0.91
- explanation annotation : MIMIC 0.714、UMN-CDR 0.695

ただし、これは主として、

- 証拠が十分か
- どの記述が根拠か

についてのLLMアノテーションと人手アノテーションの一致度です。

これは、**masking**後も正解診断が変わらないことを確認した専門家レビューの評価値ではありません。両者を区別する必要があります。

9. ConfiDxのモデル構造

ConfiDxは単一の複雑な指示で一度にすべてを出力させるのではなく、4つのinstruction taskに分解しています。  Uncertainty-aware large languag...

数理的には次のように整理できます。

9.1 疾患診断

$$\hat{y}_i = f_{\text{DD}}(x_i)$$

出力：

$$\hat{y}_i = \text{最も可能性の高い疾患名}$$

9.2 診断説明

$$\hat{E}_i = f_{\text{DE}}(x_i, \hat{y}_i)$$

出力：

$$\hat{E}_i = \{\text{診断を支持するカルテ内記述}\}$$

9.3 不確実性認識

$$\hat{u}_i = f_{\text{UR}}(x_i, \hat{y}_i, \hat{E}_i)$$

出力：

$$\hat{u}_i \in \{\text{sufficient, incomplete}\}$$

9.4 不確実性説明

$$\hat{R}_i = f_{\text{UE}}(x_i, \hat{y}_i, \hat{E}_i)$$

出力：

$$\hat{R}_i = \{\text{満たされていない診断基準}\}$$

この構造では、最初の診断 $\hat{y}_i$ を誤ると、後続タスクが誤った疾患の基準を参照するため、誤りが伝播します。

著者らも、最も可能性の高い診断を特定できなければ、疾患ごとに異なる診断基準を選べず、不十分な証拠を正しく認識できないと説明しています。  Uncertainty-aware large languag...

10. 診断基準をモデルにどのように学習させたか

10.1 Instruction fine-tuning

各学習例は、

1. 患者ノート
2. タスク指示
3. 構造化された正解出力

から構成されます。

概念的には、

$$d_{ik} = (\text{instruction}_k, x_i, o_{ik}), \quad k \in \{\text{DD}, \text{DE}, \text{UR}, \text{UE}\}$$

です。

公開リポジトリ上でも、各タスクのデータはinstruction、input、outputを持つJSON形式として整理されています。  [GitHub](#)

10.2 推論時に診断基準を渡すか

比較条件には重要な違いがあります。

Fine-tuned ConfiDx

推論時には診断基準を明示的に渡しません。学習データを通して、診断基準と多様な臨床表現との対応関係を内部化させます。

Off-the-shelf baseline

baselineには、予測した疾患に対応する診断基準をプロンプト内で与えます。

補足資料の不確実性判定プロンプトでは、baselineはノート、診断、診断基準を受け取り、すべてのcriteria entriesが満たされているかを判定します。一方、fine-tuned modelは基準を外部入力せずに判定します。

 Springer Nature

これは、ConfiDxが診断基準を「検索して参照するRAG」ではなく、主にfine-tuningによってパラメータ内部に学習する設計であることを意味します。

11. 学習目的関数

著者らは、

- 疾患診断：cross-entropy loss
- 不確実性認識：cross-entropy loss
- 診断説明：soft F1 loss
- 不確実性説明：soft F1 loss

を使用しています。  Uncertainty-aware large languag...

全体を概念的に表すと、

$$\mathcal{L} = \lambda_{\text{DD}} \mathcal{L}_{\text{DD}}^{\text{CE}} + \lambda_{\text{DE}} \mathcal{L}_{\text{DE}}^{\text{softF1}} + \lambda_{\text{UR}} \mathcal{L}_{\text{UR}}^{\text{CE}} + \lambda_{\text{UE}} \mathcal{L}_{\text{UE}}^{\text{softF1}}$$

です。

診断タスクについては、生成系列 $o_{i1}, \dots, o_{iT}$ に対するtoken-level cross entropyとして、

$$\mathcal{L}_{\text{DD}}^{\text{CE}} = - \sum_i \sum_{t=1}^{T_i} \log p_{\theta}(o_{it} \mid o_{i,<t}, x_i, \text{instruction})$$

と表現できます。

不確実性の2値分類を通常形で表すと、

$$\mathcal{L}_{\text{UR}}^{\text{CE}} = - \sum_i [u_i \log p_i + (1 - u_i) \log(1 - p_i)]$$

です。

一般的なsoft F1は、

$$\text{softF1}(\mathbf{p}, \mathbf{z}) = \frac{2 \sum_k p_k z_k}{\sum_k p_k + \sum_k z_k + \epsilon}$$

$$\mathcal{L}^{\text{softF1}} = 1 - \text{softF1}$$

と書けます。

ただし、論文はsoft F1を、予測説明数と正解説明数の違いやitem-by-item比較に対応するために用いたとしていますが、

- 説明項目をどう対応付けたか
- soft F1をtoken単位、span単位、項目単位のどこで計算したか
- 各タスクの重み λ
- task sampling ratio

の詳細な数式は記載していません。

したがって、上式は論文記載を忠実に抽象化したものであり、著者が掲載した完全な実装式ではありません。

12. 使用モデルと学習設定

使用した70Bモデルは次の4つです。

- LLaMA-3.1-70B-Instruct
- DeepSeek-R1-Distill-Llama-70B
- BioLLaMA-70B
- Med42-70B

LoRAによるparameter-efficient fine-tuningを行っています。

主な設定は、

- batch size : 4
- epoch : 10
- maximum learning rate : 1×10^{-4}
- warm-up ratio : 0.01
- LoRA rank : 8
- LoRA alpha : 16
- LoRA dropout : 0.05
- GPU : NVIDIA A100 80GB $\times$ 10

です。追加のhyperparameter tuningは行っていません。

Uncertainty-aware large languag...

13. 評価指標

13.1 診断不確実性の認識

論文の $Accuracy^{EU}$ は、

$$Accuracy^{EU} = \frac{\text{止しく uncertain と認識した件数}}{\text{全 uncertain 件数}}$$

です。

Uncertainty-aware large languag...

混同行列で書くと、

$$Accuracy^{EU} = \frac{TP}{TP + FN}$$

なので、通常の分類用語では**uncertain class**に対する**recall**に相当します。「Accuracy」という名称ですが、全症例に対するaccuracyではありません。

さらに、

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

$$F_1^{EU} = \frac{2 \cdot Precision \cdot Recall}{Precision + Recall}$$

を使用しています。

13.2 説明の評価

診断説明には、

- METEOR
- BERTScore
- SentenceBERT
- Interpretation Accuracy

を使用しています。

$$Interpretation\ Accuracy = \frac{\text{止しく生成された説明項目数}}{\text{全正解説明項目数}}$$

不完全証拠に対する説明には、

$$Interpretation\ Accuracy^{EU} = \frac{\text{止しく生成された不足説明項目数}}{\text{全不足説明項目数}}$$

を用いています。  Uncertainty-aware large languag...

人手評価では、

- medical correctness
- completeness

を5段階評価しています。

2名の医師が独立評価し、不一致は3人目が解決しました。診断説明はcomplete 50件、incomplete 50件、uncertainty explanationはincomplete 100件を評価しています。  Uncertainty-aware large languag...

14. 主な結果

14.1 MIMICテストセット

疾患診断

Off-the-shelfモデルの診断accuracyは、

0.197～0.218

でした。

Fine-tuning後は、すべてのモデルで68.3%以上の相対的改善が報告されています。

 Uncertainty-aware large languag...

不確実性認識

Off-the-shelfモデルの最高値は、

- $Accuracy^{EU} = 0.057$
- $F_1^{EU} = 0.102$

でした。

ConfiDxでは、

- $Accuracy^{EU} = 0.594 \sim 0.658$
- $F_1^{EU} = 0.644 \sim 0.709$

まで改善しました。  Uncertainty-aware large languag...

これは、一般的なLLMが、診断根拠が削除されていても「情報は十分である」と過大評価しやすいことを示しています。

14.2 説明性能

診断説明のInterpretation Accuracyは、baselineで、

0.446～0.563

でした。

Fine-tuningによる改善率は25.3～43.8%でした。

不確実性説明はさらに差が大きく、

- off-the-shelf平均：約0.017
- ConfiDx：0.214～0.245

でした。  Uncertainty-aware large languag...

絶対値としてはuncertainty explanationがまだ十分に高いとは言えませんが、baselineとの差は大きい結果です。

14.3 未知疾患MIMIC-U

ConfiDxが学習時に見ていない6疾患では、

- 診断accuracy：0.263～0.294
- 平均 $Accuracy^{EU}$ ：0.471
- 平均 F_1^{EU} ：0.497

でした。

Baselineは、

- 平均 $Accuracy^{EU}$ ：0.046
- 平均 F_1^{EU} ：0.083

でした。  Uncertainty-aware large languag... +1

診断accuracy自体は高くありませんが、診断基準と臨床表現の対応関係を学習したことによって、未学習疾患でも一定のevidence sufficiency判定が可能だったと著者らは解釈しています。

14.4 外部施設UMN-CDR

UMN-CDRでは、

- 平均 $Accuracy^{EU} = 0.497$
- 平均 $F_1^{EU} = 0.569$

でした。

施設が変わり、ノート長や記載様式が異なっても、fine-tuned modelはbaselineより高い性能を示しました。

14.5 大規模商用LLMとの比較

PMCおよびNEJMの公開症例に対して、

- GPT-4o
- OpenAI o1
- Gemini 2.0
- Claude 3.7
- DeepSeek-R1

を比較しています。

商用・大規模モデルのPMCでの不確実性認識accuracyは0.45～0.65、平均0.52でした。一方、ConfiDxは0.80～0.90の範囲でした。

ただし、この比較では商用モデルに、

- 正解診断
- 対応する診断基準

を与え、不確実性認識だけを評価しています。したがって、これは完全なend-to-end診断能力の比較ではありません。

14.6 医師との協働

MIMIC-Uから200件を抽出し、

- ConfiDx単独
- 医師単独
- ConfiDx支援医師

を比較しました。

医師の初期診断をConfiDxに入力し、ConfiDxの説明と不確実性判定を再び医師に提示する設計です。

ConfiDx支援により、医師単独と比較して、

- 不確実性認識：10.7%向上
- 診断説明：14.6%向上
- 不確実性説明：26.3%向上

しました。

一方、診断accuracy自体は大きく改善しませんでした。

これはConfiDxの主要な価値が、「医師より正確に診断すること」ではなく、

医師が出した診断について、証拠不足を検出し、見落としている不足項目を提示すること

にあることを示しています。

15. この論文の方法を一つの数理モデルとしてまとめる

患者 i について、

- x_i^{raw} ：元カルテ
- y_i ：正解診断
- C_{y_i} ：診断基準

- x_i^+ : evidence-complete note
- x_i^- : evidence-incomplete note
- E_i : 診断支持根拠
- R_i : 不足基準
- u_i : 不確実性ラベル

とします。

全体は次のようにまとめられます。

1. 診断リーク除去

$$x_i = \rho(x_i^{\text{raw}}; y_i)$$

2. 診断根拠抽出

$$E_{ij} = \text{Examiner}(\text{Extractor}_{1:4}(x_i, y_i, c_{y_i,j}))$$

3. 診断基準の充足判定

$$s_{ij} = 1[E_{ij} \text{が基準 } c_{y_i,j} \text{を支持}]$$

4. 必要に応じてcomplete noteを合成

$$x_i^+ = x_i \oplus G(\{c_{y_i,j} : s_{ij} = 0\})$$

5. 診断根拠をマスク

$$x_i^- = \mathcal{M}(x_i^+; \{E_{ij} : j \in M_i\})$$

6. 不確実性ラベル

$$u_i = 1 - g_{y_i}(s_{i1}(x_i^-), \dots, s_{im}(x_i^-))$$

論文のpromptに近いAND型なら、

$$u_i = 1 - \prod_j s_{ij}(x_i^-)$$

7. 不確実性説明

$$R_i = \{c_{y_i,j} : s_{ij}(x_i^-) = 0\}$$

8. 専門家による診断不変性確認

$$V_{\text{expert}}(x_i^+, x_i^-, y_i) = 1$$

9. モデル出力

$$\hat{y}_i = f_{\text{DD}}(x_i^-)$$

$$\hat{E}_i = f_{\text{DE}}(x_i^-, \hat{y}_i)$$

$$\hat{u}_i = f_{\text{UR}}(x_i^-, \hat{y}_i, \hat{E}_i)$$

$$\hat{R}_i = f_{\text{UE}}(x_i^-, \hat{y}_i, \hat{E}_i)$$

理想的には、

$$\hat{y}_i = y_i, \quad \hat{u}_i = 1, \quad \hat{R}_i = R_i$$

となることを目標にします。

16. 方法論的な強み

16.1 不確実性を説明可能な教師ラベルに変換した

通常の「モデルの自信」は直接観察できません。

一方、本研究では、

診断基準 – カルテ内の証拠 = 不足情報

として、不確実性の理由を明示的に定義しています。

そのため、

- 不確実性の有無
- 不足している基準
- 診断を支持する残存根拠

を個別に評価できます。

16.2 正解診断を固定したcounterfactual設計

通常の実カルテでは、情報不足症例について、

本当に同じ疾患だったのか
それとも別の疾患だったのか

が曖昧です。

本研究ではcomplete noteから根拠を削除することで、

same disease + different evidence availability

という制御された比較を作っています。

これは、診断情報不足検出モデルを評価するための合理的な合成データ設計です。

16.3 診断と証拠十分性を分離した

ConfiDxは、

- どの疾患が最も可能性が高いか
- その疾患を確定してよいか

を分けています。

これは臨床推論に近い設計です。

most likely diagnosis $\neq$ definitively established diagnosis

という関係を扱える点が重要です。

17. 方法論的な限界

17.1 「不確実性」はevidence completenessに限定される

本研究が扱うのは、

evidence uncertainty

であり、以下は直接評価していません。

- 疾患間の確率分布
- aleatoric uncertainty
- epistemic uncertainty
- calibration
- out-of-distribution detection
- 選択的予測・abstention
- 鑑別診断間の相対的確信度

したがって、「uncertainty-aware」という名称は広いものの、実際のタスクは、

診断基準に必要な情報がノートに記録されているか

というbinary completeness classificationに近いです。

17.2 診断基準の論理構造が十分に形式化されていない

診断基準には通常、ANDだけではなく、

- OR
- k -of- n
- 閾値
- 除外条件
- 時間条件
- 他疾患との鑑別条件

が含まれます。

本研究は基準の各entryを順に確認し、補足プロンプトでは「すべてのentries」を満たすかを尋ねていますが、疾患固有の論理構造を明示的なBoolean expressionやdecision graphとして実装した記載はありません。

したがって、ラベルが厳密には、

臨床的に診断可能か

ではなく、

著者らが列挙した基準項目がすべて文書化されているか

に近くなる可能性があります。

17.3 Complete noteにも合成情報が含まれる

不足基準をGeneratorが補完してcomplete noteを作るため、モデルは、

- 人間が記録した自然な臨床記述
- LLMが生成した臨床記述

の文体差を学習する可能性があります。

その場合、モデルが真に診断基準の不足を学習するのではなく、

synthetic text style

を手掛かりにcomplete/incompleteを識別するリスクがあります。

この点に対する、

- 合成記述と実記述の識別実験
- 人間による自然さ評価
- generatorを変えた外部検証
- masking artifactだけを検出していないかの検証

は報告されていません。

17.4 Masking policyの再現性が不足している

本研究の最も新規性が高い部分はevidence maskingですが、その具体的アルゴリズムが十分に公開されていません。

したがって、この論文を基に新しい研究を行う場合は、少なくとも次を明示的に定義する必要があります。

$$P(M_i | C_{y_i}, E_i, x_i)$$

すなわち、

どの基準を、どの確率で、何個、どの粒度で削除するか

というmasking policyです。

17.5 Expert validationの報告が不十分

「専門家が診断不変性を確認した」という記述はありますが、その再現可能な手順と定量評価がありません。

本来は例えば、

$$Agreement_{\text{preserve}} = \frac{\sum_i 1[V_i^{(1)} = V_i^{(2)} = 1]}{N}$$

や、

$$\kappa_{\text{preserve}}$$

を報告する必要があります。

また、不適切なmaskingとして除外された割合、

$$Rejection\ Rate = \frac{N_{\text{rejected}}}{N_{\text{reviewed}}}$$

も重要です。

17.6 Complete/incompleteの1対1バランス

データではcompleteとincompleteが1対1になるよう調整されています。 [Uncertainty-aware large languag...](#)

これは学習には便利ですが、実臨床で情報不足症例が50%とは限りません。

したがって、このテストセットで得られたaccuracy、precision、F1から、実際の病院に導入した際の、

- positive predictive value
- false alert burden
- alert fatigue
- calibration

を直接推定することはできません。

17.7 診断accuracyの絶対値は限定的

不確実性認識では大幅に改善していますが、未知疾患MIMIC-Uでの診断accuracyは0.263～0.294です。

したがって、ConfiDx単独で自律的に診断を確定するシステムとしては不十分です。

実際、医師との協働実験でも、主な改善は診断accuracyではなく、

- 不確実性認識
- 診断説明
- 不確実性説明

でした。

17.8 Prospective evaluationがない

本研究は既存EHRと合成ノートを使用した後ろ向き評価です。

実際の臨床記録作成中に、

- どの情報を追加質問すべきか
- どの検査を追加すべきか
- 医師が提案を採用したか
- 記録の完全性が改善したか
- 誤診や診断遅延が減ったか

は評価していません。

著者らも、hallucinationの直接評価、別のhuman-AI workflow、商用モデルへのfine-tuningなどを今後の課題としています。

Uncertainty-aware large languag...

18. この論文を最も正確に要約すると

この研究は、次のcounterfactual taskを構築したものです。

正解診断を固定したまま、その診断を支持する文書上の証拠を制御して欠落させる

そしてモデルに、

最も可能性の高い診断 + 現在の証拠が十分か + 存在する診断根拠 + 不足している診断基

を出力させます。

特に、ユーザーが挙げた5点は次のように対応します。

項目	論文での実装
診断基準に基づく根拠抽出	4 evidence extractors + 1 examinerが、基準ごとにカルテ内記述を抽出・統合
Evidence-incomplete noteの合成	Complete noteから診断基準に対応する根拠スパンの一部をmask
情報充分性の判定	予測診断の診断基準とノート中の証拠を照合し、sufficient/incompleteに分類
不確実性理由の説明	満たされていない診断基準を列挙
正解診断不変性の確認	Domain expertsがmodified noteを確認し、maskingが診断を変更していない症例を採用

本論文の本質的な新規性は、LLMの主観的confidenceを測ることではなく、診断基準とカルテ内証拠の対応関係から、診断不確実性を監査可能なevidence gapとして定義したことです。

一方、研究を厳密に再現・発展させるために最も不足しているのは、

masking policyとdiagnosis-preservation reviewの詳細な定式化・報告

です。この2点を明示的に設計すれば、電子カルテ作成中に「確信を持った診断のために、今何を確認・記録すべきか」を提示するシステムへ、より直接的に発展させられる研究です。

情報源

PDF に変換