

昨日 22:17



PRISM Patient Records Interpretati...
PDF

この論文の内容を全て確認した上で、詳しく解説してください

1m 12s考えました

確認しました。添付された Gupta et al., "PRISM: Patient Records Interpretation for Semantic clinical trial Matching system using large language models," npj Digital Medicine, 2024; 7:305 の本文12ページを、Methods、数式、全Figure、Table、Discussion、Data/Code availabilityまで通して確認しました。

PRISM Patient Records Interpret...

この論文は単純な「患者カルテをLLMに全部入れて、治験に適格か聞く」研究ではありません。むしろ、
治験基準を小さな判定問題に分解 → 長いEHRから各問題に関係する記述をretrieval → LLMが各問題を
Yes/No/N/A判定 → Boolean logicで元の治験基準に再構成 → 臨床的重要度を考慮してtrial-level scoreを計算
→ 患者と治験をランキング

という、かなり明確なモジュール型 clinical trial matching systemを提案した研究です。これがPRISMの本質です。

PRISM Patient Records Interpret...

1. この論文が解決しようとしている問題

臨床試験、とくにがん領域では、患者が各試験の複雑なinclusion/exclusion criteriaを満たしているかを医師やclinical research coordinatorがEHRを読んで確認する必要があります。しかし成人がん患者の臨床試験参加率は約7%にとどまり、その背景の一つとして、候補試験を患者ごとに体系的に照合する作業負荷が挙げられています。

PRISM Patient Records Interpret...

さらに問題なのは、治験適格性に必要な情報の多くがstructured EHRではなく、progress note、discharge summary、pathology noteなどの非構造化テキストに存在することです。特にoncologyではcancer stageなど重要情報がstructured fieldには十分存在しない場合があります。

PRISM Patient Records Interpret...

従来は、①治験条件をSQL等で扱えるstructured queryに変換する方法、②患者記録から必要な情報を抽出してstructured representationにする方法、が主流でした。しかしルール作成が必要で、trial・疾患・EHR systemが増えるほどscalabilityが悪化します。著者らは、既存のLLM研究についても「synthetic/simple patient note」「少数のnotes」「限られたcriteria」での評価が多く、実際の患者では100~200以上存在し得る長大なEHRを十分扱っていないと位置づけています。

PRISM Patient Records Interpret... +1

そこで本論文は、

real-world oncology EHR + real clinical trial criteria + long patient history

を対象とするend-to-end systemとしてPRISMを提案しています。

2. PRISMを一枚で理解すると

Figure 6 (p.7) がこの論文で最も重要です。

患者側では、

EHR → note filtering → chunking → embedding/vector database

となります。


治験側では、

free-text eligibility criteria → GPT-3.5によるsimplified questionsへの分解 → Boolean graph

となります。

その後、

各question → relevant EHR chunksをretrieval → OncoLLMでYes/No/N/A判定 → criterion-level resultへ再構成 → weighted scoring → trial ranking

という流れです。 

つまり構造としては、

$$\text{Trial criteria} \rightarrow \{q_1, \dots, q_m\}$$

$$\text{Patient EHR} \rightarrow \{c_1, \dots, c_n\}$$

$$q_j \rightarrow \text{retrieve relevant } c_i \rightarrow LLM(q_j, c_i) \rightarrow a_j \in \{\text{Yes, No, N/A}\}$$

$$\{a_j\} \rightarrow \text{Boolean composition} \rightarrow \text{criterion result} \rightarrow \text{trial score}$$

です。

ここは非常に重要で、PRISMは一つの巨大なpromptで患者全記録と全criteriaを同時判定するモデルではありません。

3. 数理的な問題設定

Methodsでは、患者を P 、その患者のnotesを

$$N = \{n_1, n_2, \dots, n_i\}$$

とします。

治験 T のcriteria textから、

$$Q = \{q_1, q_2, \dots, q_j\}$$


という質問集合を生成します。

各質問に対して、

$$A = \{a_1, \dots, a_j\}, \quad a_j \in \{\text{Yes, No, N/A}\}$$


を推定します。ここでN/Aは、

- patient recordから答えを決定できない
- questionがpatientにapplicableではない

場合をまとめて表しています。 

そして各questionの答えをlogical composition C で統合し、

$$S = f(C(a_1, a_2, \dots, a_j))$$

として患者と治験のmatching scoreを計算します。スコアが高いtrialほど患者に適合すると考え、rankingします。 

したがって、この論文は単なるbinary classificationではなく、

criterion decomposition + evidence retrieval + QA + logical aggregation + learning-to-rankに近い scoring

という複合問題として臨床試験matchingを定式化しています。

4. データセット設計

ここは少し複雑なので、評価データを分けて理解する必要があります。

Ranking用データ

institutional clinical research data warehouseからdeidentified oncology EHRとclinical trial enrollment informationを取得しています。

患者が複数trialに参加していた場合には、その患者について**inclusion/exclusion criteria text**が最も長い**trial**を1つ選び、それをground-truth trialとしています。また患者記録は**実際のtrial enrollment date**までに限定しています。

PRISM Patient Records Interpret...

最終的に98 patient-ground-truth-trial pairsを作成しています。

さらに各患者についてnegative candidate trialを作成します。その条件は、

同じcancer typeであり、患者がそのtrialに実際にはenrollしておらず、患者がground-truth trialにenrollした時点でClinicalTrials.gov上activeだったtrial、です。

これによって、

$$98\ patients \times 10\ trials = 980$$

patient-trial pairsが作成されました。

PRISM Patient Records Interpret...

5. Table 1：患者のがん種

Table 1では次の内訳です。

Cancer type	Patients	平均documents/patient
Breast cancer	37	49
Lung cancer	20	76
Prostate cancer	29	57
Colorectal cancer	7	283
Skin cancer	4	52

PRISM Patient Records Interpret...

ここには論文内の小さな不整合があります。Table 1の患者数を合計すると

$$37 + 20 + 29 + 7 + 4 = 97$$

ですが、本文では98 patientsとされています。本文中ではこの1名の差について説明されていません。

6. PRISM Module 1：Trial composition

これはPRISMの中でもかなり重要な工夫です。

ClinicalTrials.govのfree-text inclusion/exclusion criteriaをそのままpatient EHRと比較するのではなく、GPT-3.5を使って、

単純で独立した**Yes/No/N/A question**

に分解します。

一つの**criterion**が複数条件を含む場合は複数**question**へ分解され、その関係をBoolean logicで保存します。著者らはこれを****disjunctive normal form (DNF) ****として表現しています。

PRISM Patient Records Interpret...

p.8のFigure 7が非常に分かりやすい例です。

元の**criterion**は、

「study entry時にprogressive diseaseであり、次の1つ以上を満たす」


という条件で、

1. 3回以上のPSA上昇
2. さらにPSA ≥ 2 ng/mL
3. RECIST 1.1によるsoft tissue progression
4. PCWG3によるbone disease progression

です。

これを、

$$(Q_1 \wedge Q_2) \vee Q_3 \vee Q_4$$

と変換します。 

つまりLLMに、

「この複雑なcriterion全体を満たすか？」

と一気に聞くではありません。

まず、

「3回以上PSAが上昇しているか？」

「PSA ≥ 2 ng/mLか？」

「RECIST 1.1でprogressionか？」

というatomic questionにするわけです。

この設計によってLLMに複雑な論理条件を同時に解かせる負荷を減らしています。

7. Trial compositionの精度


50 trialsについて人手評価しています。

著者らによると、

question omission：約1%

incorrectly formed questions：約2%

Boolean logic correctness：約89%

でした。さらにこのmoduleを入れた方がend-to-end performanceも改善したとしています。ただしその詳細なablation結果はSupplementary Note 5にあります。 

ここで重要なのは、**trial criteria decomposition**自体も完全ではないということです。


QAモデルが100%正しくても、上流でBoolean graphが11%程度間違えば、最終trial eligibilityに誤りが伝播する可能性があります。

8. Module 2：EHR chunking

一人の患者にhundreds of notesがあり、そのままLLM contextに入らないため、EHRをchunk化します。

spaCy sentence tokenizerを使い、各chunkを3文とし、

中央の文に対して前後1文ずつを含めるようなone-sentence overlapを採用しています。

目的は、医学情報がchunk boundaryで分断されることを防ぐことです。 

これは一般的な固定token長chunkingよりも、

に近い設計です。

9. 重複EHR記述の削除

EHRでは過去のnoteがcopy-forwardされることが多いため、同一・類似chunkをそのまま残すと、同じ情報が何十回もvector databaseに入ってしまう。

そこで、

完全一致するchunkは除外し、既存chunkとのembedding cosine similarityが0.96以上のものもduplicateと判断し、duplicate間では**最新のchunkだけを残します**。

PRISM Patient Records Interpret...

これはEHRを扱う上でかなり実務的な設計です。

10. Module 3 : Embedding / Retrieval

各chunkをembeddingしてvector storeに格納します。

retrievalには、

Azure OpenAI Ada embedding model

を使用し、

$$\cos(\mathbf{e}_q, \mathbf{e}_c)$$

すなわちtrial criterionから作成したqueryとEHR chunkのembedding cosine similarityで関連chunkを検索します。

PRISM Patient Records Interpret...

したがってPRISMでは、

LLM本体の前にembedding-based retrieverが存在します。

これは論文全体を理解するうえで非常に重要です。

PRISMは、

全note → LLM

ではなく、

全note → chunk → embedding → retrieval → relevant chunks → LLM

です。

11. Module 4 : Question Answering

retrieverが取得したchunksをOncoLLMまたは比較LLMへ渡します。

一般的なRAGではretrieval score順にchunkを並べることが多いですが、PRISMでは**chronological order**に並べ直します。

さらに各chunkについて、

- note date
- note type

を付け、patient ageとenrollment dateも提示します。

これは特に、

「以前は～だったが現在は～」

「治療後にprogressionした」

といったtemporal reasoningを改善するためです。著者らはchronological orderingによってtemporal questionの精度が改善したと報告しています。

PRISM Patient Records Interpret...

12. PromptingとLLM出力

zero-shot prompting、temperature 0を使用しています。

出力はJSON形式で、主に4要素です。

Question explanationでは、そのquestionが何を要求しているか、どう判断すべきか、追加で何の情報が必要かをモデルに整理させます。

Answer explanationではpatient recordを根拠として解釈します。

AnswerはYes / No / N/Aです。

Confidenceは1～5です。

PRISM Patient Records Interpret...

論文ではChain-of-Thought型の段階的推論を利用したと説明されています。

なおMethods本文のscoring式を見る限り、この**confidence 1–5は最終trial scoreに直接入っていません**。主に回答品質やモデル挙動を表す補助情報として出力されています。

13. N/Aをどう扱っているか

これはこの論文で最も興味深い数理部分の一つです。

複数questionで構成されたcriterionのうち一部がN/Aの場合、単純にcriterion全体をN/Aにはしません。

N個のunknown questionがあれば、そのYes/No combinations

$$2^N$$

通りを考え、それぞれを同確率

$$\frac{1}{2^N}$$

と仮定してcriterion成立確率を計算します。

PRISM Patient Records Interpret...

その上で、

$$P(\text{criterion met} \mid \text{data}) > 0.66$$

ならMet、

$$P(\text{criterion met} \mid \text{data}) < 0.34$$

ならNot Met、

その中間ならN/Aとします。

PRISM Patient Records Interpret...

例えば、

$$Q_1 \wedge Q_2$$

というcriterionで、

$$Q_1 = \text{No}, \quad Q_2 = \text{N/A}$$

なら、Q2の答えが何であってもcriterionはFalseなので、N/AにはせずNot Metとできます。

これは合理的なBoolean propagationです。

一方で後で述べるように、**N/Aをすべて50:50のlatent Yes/Noと仮定する点には統計的な弱点があります**。

14. Module 5 : Trial-level scoring

criterionを判定した後に、trial全体としてどれだけpatientに合っているかをスコア化します。

この論文では3種類を比較しています。

Simple score

$$S_{\text{simple}} = \frac{\# \text{Criteria Met}}{\# \text{Total Criteria}}$$

という単純な割合です。 [PRISM Patient Records Interpret...](#)

ただし臨床的には、

「cancer typeが違う」

ことと、

「lab valueが少し基準外」

を同じ1 criterionとして扱うのは不自然です。

そこでtierを導入します。

15. Criteria Tier

oncologist等との議論に基づいてcriteriaを、

$$T_1, T_2, T_3, T_4$$

の4段階に分けます。

Tier 1が最重要です。

例えばcancer typeやhistologyは、そこを外しただけで基本的にtrial候補から除外される可能性が高い一方、laboratory valuesなどは時点によって変化するため相対的にflexibleです。 [PRISM Patient Records Interpret...](#)

concept-level evaluationでは全体で13 conceptsに分類し、

$$Tier1 > Tier2 > Tier3 > Tier4$$

としています。 [PRISM Patient Records Interpret...](#)

p.2のradar chartでは、cancer stage、cancer subtype、cancer type、prior treatment/surgery、comorbidities、lab/imaging、genetic/biologic markers、cancer grade/histologyなどが示されています。

16. Iterative Tier

最重要Tierから順番に確認し、重要なcriterion violationが発生した時点でそれ以降を重視しない方法です。

$$S_{\text{iterative}} = \frac{\text{violationまでに満たしたcriteria数}}{\text{total criteria}}$$

です。 [PRISM Patient Records Interpret...](#)

Figure 8Bでは、Tier 2でviolationが出たところで“STOP”しています。 [PRISM Patient Records Interpret...](#)

17. Weighted Tier

著者らが最終的に最も良い結果を得た方法です。

criterion単位では基本的に、

Met → +1
N/A → +0.5
Tier 1のNot Met → −0.5
それ以外のNot Met → 0

として計算し、それぞれのtierについて平均scoreを作り、tier weightを掛けます。p.9 Figure 8Cにこの構造が図示されています。 [PRISM Patient Records Interpret...](#)

重みは、

$$w_1 = 2, \quad w_2 = 1.5, \quad w_3 = 1, \quad w_4 = 0.5$$

です。これは学習された値ではなく、今回の研究で固定したheuristicです。著者自身も将来的にはoptimization可能としています。 [PRISM Patient Records Interpret...](#)

18. OncoLLMとは何か

PRISMそのものとOncoLLMは区別する必要があります。

PRISM = システム全体

OncoLLM = PRISMのQA部分で使用される14B oncology-specialized LLM

です。

ベースモデルは、

Qwen-1.5 14B

です。

single cancer centerのoncology EHRを利用してfine-tuningし、real-world dataとsynthetic dataの両方を使っています。 [PRISM Patient Records Interpret...](#)

19. OncoLLMのfine-tuning

Supervised Fine-TuningとLoRAを使用しています。

設定は、

$$rank = 64, \quad \alpha = 32, \quad dropout = 0.1$$

です。

training dataには、

several thousand manually annotated question–chunk pairs

と、

2 billion tokens以上のsynthetic oncology “book” data

を利用しています。 [PRISM Patient Records Interpret...](#)

clinical training dataは5,790人以上のがん患者です。

training hyperparametersは、

learning rate = 0.0003

batch size = 1

gradient accumulation = 16

clinical data = 5 epochs

synthetic data = 1 epoch

で、8台のA100 GPUを使用し、1500 GPU-hours以上とされています。評価対象patient/trialはtrainingには含まれていません。

PRISM Patient Records Interpret...

20. Question-level benchmark

ここからが主要結果です。

50 cancer patients、約10,000 notesから720 eligibility questionsを作り、医師annotatorによるground truthを作っています。

PRISM Patient Records Interpret...

主要結果は以下です。

Model	全720 questions	N/A GT除外
Random	34%	—
GPT-3.5 Turbo	53%	48%
MedLlama	55%	56%
Meditron	51%	54%
TrialLlama	57%	59%
Mistral-7B-Instruct	41%	32%
Mixtral-8×7B-Instruct	49%	43%
Qwen14B-Chat	43%	34%
OncoLLM	63%	66%
GPT-4	68%	72%
Expert doctors*	70%	—

MeditronとTrialLlamaはcontext lengthが4kのため約30%のsamplesしか処理できませんでした。

PRISM Patient Records Interpret... +1

つまり、

$$GPT4(68\%) > OncoLLM(63\%) > GPT3.5(53\%)$$

です。

McNemar testでOncoLLM vs GPT-3.5の差は

$$p = 0.0013$$

でした。

PRISM Patient Records Interpret...

したがって、この論文はOncoLLMがGPT-4を超えたとは主張していません。

主張は、

14Bというかなり小さいモデルながらGPT-4に比較的近く、GPT-3.5や同規模open modelsより高いです。

21. 「医師と同程度」という主張をどう理解するか

Figure 1ではexpert doctorsが70%、OncoLLMが63%、GPT-4が68%です。

ただしdoctor benchmarkは全720 questionsではありません。最終的なhuman comparisonには109 questionsが用いられています。

annotationでは最初に5名のmedical doctorsを使い、その後selected annotatorsを用いて109 questionsで inter-annotator reliabilityを評価しました。agreement自体も約64～70%でした。

PRISM Patient Records Interpret...

したがって、

「OncoLLMが医師と完全に同等」

というより、

この限定されたannotation subsetでは、モデルaccuracyがhuman inter-annotator performanceに近い範囲に来た

と理解する方が適切です。

22. N/Aが非常に重要

Ground truthがN/Aだったquestionsを除くと、

OncoLLM：

63% → 66%

GPT-4：

68% → 72%

と改善しました。

一方でGPT-3.5や多くのopen modelsはむしろaccuracyが下がりました。著者らは、弱いモデルでは ambiguous inputに対してN/Aを出すことが見かけ上accuracyを支えている可能性を指摘しています。

PRISM Patient Records Interpret...

p.3 Figure 2は、

accuracy × N/A frequency × model size

をbubble plotで示しています。

OncoLLMとGPT-4はhuman annotatorsのN/A frequencyに比較的近いというのが著者の解釈です。

PRISM Patient Records Interpret...

23. Concept-wise performance

各questionをoncology conceptに分類して性能を調べています。

13 concepts、4 tiersです。

分類自体にはGPT-4を使い、concept taxonomyはphysician inputに基づいています。

PRISM Patient Records Interpret...

p.2のFigure 1BではOncoLLMは多くのconceptでGPT-4に次ぐperformanceで、特に**biomarker-related questions**ではGPT-4を上回ったと報告しています。

PRISM Patient Records Interpret...

24. Patient-centric ranking

次に、

「この患者にどのtrialを勧めるか」

を評価します。

98 patientsそれぞれについて、同じcancer typeの10 trialsを候補にし、そのうち1つが実際に患者がenrollしたground-truth trialです。

評価指標は、

ground-truth trialがTop 3に入る割合

です。

clinical research coordinatorsへのinterviewから、現場では2〜3 trialsをshortlistするworkflowが一般的だったためTop-3を採用したと説明しています。

PRISM Patient Records Interpret...

結果は、

OncoLLM Weighted Tier：約0.65

GPT-3.5：約0.59

OncoLLM Iterative：約0.63

GPT-3.5：約0.61

OncoLLM Simple：約0.62

GPT-3.5：約0.57

でした。

PRISM Patient Records Interpret...

Figure 3AではWeighted Tier OncoLLMが最良です。

PRISM Patient Records Interpret...

25. Ground-truth trialに対するcriterion判定

患者は実際にground-truth trialへ参加しているので、理想的には多くのcriteriaがMetになるはずですが、

98 ground-truth patient-trial pairsについて、

OncoLLMでは平均約62%のcriteriaをMetと判定し、

GPT-3.5では55.4%

でした。

PRISM Patient Records Interpret...

ground-truth trialがTop 3にrankされた症例だけを見ると、

OncoLLM 66.7%

GPT-3.5 59%

まで増えています。さらにOncoLLMの方がN/Aが少ないです。

PRISM Patient Records Interpret...

p.4 Figure 4がこの結果を、

Met / Not Met / N/A

の割合として示しています。

PRISM Patient Records Interpret...

26. Trial-centric search

PRISMは逆方向にも利用できます。

つまり、

「患者Pにtrialを探す」

だけでなく、

「trial Tに適格そうな患者を病院内から探す」

こともできます。

36 trialsについて、それぞれtrial実施期間中に同じcancer typeだった患者を候補にしています。

各trialには平均、

ground-truth patients :

$$2 \pm 1$$

additional patients :

$$13 \pm 8$$

が含まれます。 

evaluationはbinary relevanceを用いたNDCGです。

Weighted Tierでは、

OncoLLM :

$$NDCG = 0.68$$

GPT-3.5 :

$$NDCG = 0.62$$


でした。

Iterative Tier :

$$0.66 \text{ vs } 0.63$$

Simple :

$$0.62 \text{ vs } 0.62$$

です。 

したがってWeighted Tierがpatient→trialとtrial→patientの双方で最も安定して良いというのが主要結論です。

27. 非ground-truth trialが実は正解だった問題

この論文でかなり重要なerror analysisです。

ランキングでは、

実際にenrollしたtrial = relevant
enrollしなかったtrial = negative

としています。

しかし当然、

参加しなかったtrialにも患者が適格だった可能性があります。

そこでOncoLLMがTop 1にrankしたものの、実際には患者が参加しなかった10 trialsをclinical data expertが
人手確認しました。

すると、

著者らはこれを踏まえて、「真のTop-3 accuracyは約95%まで上がる」と述べています。

PRISM Patient Records Interpret...

ただしこれは非常に慎重に読む必要があります。

10例だけのmanual reviewから全98 patientsについて95%と推定するのはかなり強いextrapolationです。

一方で、この結果自体は、

historical enrollmentを**ground truth**にする**clinical trial matching benchmark**には**label noise**が非常に大きい

ことを示しており、むしろ方法論的には重要です。

28. ExplanationとEvidence Citation

OncoLLMの出力は単にYes/Noではなく、

なぜそう判断したか + EHRのどこが根拠か

を出します。

医療専門家によるreviewでは、

final answer accuracy :

75.26%

final answerがcorrectだった症例におけるexplanation accuracy :

90.91%

citation :

correct 86.71%

partially correct 6.29%

でした。 PRISM Patient Records Interpret...

これはPRISMが完全自動判定というより、

AIがcandidate screening + evidence groundingを行い、人間が最終確認する

仕組みに向いていることを示しています。

29. 「患者の最新noteだけ読めば十分か？」

著者らは980 patient-trial pairsについて、OncoLLMが各criterionの根拠として引用した最も古いchunkと最も新しいchunkの日付を調べています。

結果として必要な情報が1年以上にわたって分散するpatientも存在しました。

一方、重要情報の多くは最近のnote側、特にpatient journey後半50%に存在していました。

PRISM Patient Records Interpret...

Figure 5はこのdistributionを示しています。 PRISM Patient Records Interpret...

著者の結論は、

最近のnoteは特に重要だが、必要情報がどこにあるか事前に予測できないため、patient journey全体へのアクセスが望ましい

です。

これは長期EHRを対象にした本研究の重要なメッセージです。

30. Cost analysis

98 patients × 10 trials、つまり980 patient-trial matchingについてコストを比較しています。

OncoLLM :

約\$170

GPT-4 :

約\$6,055

と推計しています。

patient-trial pairあたり、

OncoLLM :

\$0.17

GPT-4 :

\$6.18

で、約35倍の差です。 [PRISM Patient Records Interpret...](#)

OncoLLMのfine-tuning自体は、

8 × NVIDIA A100 40GB

約7日

で、training costを約\$2,688と推計しています。 [PRISM Patient Records Interpret...](#)

つまり著者の主張は、

initial fine-tuning costは必要だが、多数patientをscreeningすればsmall local modelの方が十分amortizeできる

というものです。

31. なぜOncoLLMを使うのか

性能だけではありません。

医療では、

外部APIにpatient dataを送れない

というprivacy問題があります。

GPT-4等の巨大proprietary modelに対して、14B OncoLLMなら病院内またはprivacy-compliant infrastructureにself-hostできるという点を著者らは強調しています。 [PRISM Patient Records Interpret...](#)

論文全体として、

「巨大general LLMでなくても、domain/task-specific fine-tuningした比較的小型モデルならclinical applicationに使える」

というメッセージがかなり強く出ています。 [PRISM Patient Records Interpret...](#)

32. Discussionで著者らが主張していること

著者らの主要な結論は、

LLM + retrieval + Boolean decomposition + criterion weightingによって、real-world EHRからclinical trial matchingをend-to-endで行うことは現実的である

というものです。  PRISM Patient Records Interpret...

特にこの研究の差別化点として、

従来研究では2~5 notes、単一trial、13 criteria程度だったのに対して、本研究ではpatientの長いEHR、200以上のtrials、約10,000 diverse criteriaを扱ったとしています。  PRISM Patient Records Interpret...

またclinical research coordinatorが実際にはすべてのcriteriaを等価には扱わないことを踏まえ、

clinical importanceによる**tier/weighting**

を**ranking**へ導入した点も重要としています。  PRISM Patient Records Interpret...

33. 著者自身が認めているLimitations

第一は、

unstructured noteしか使っていないこと

です。

lab valuesなどはstructured EHRにしか存在しないことが多いため、今後は、

structured data + unstructured text

の**hybrid retrieval**が必要としています。  PRISM Patient Records Interpret...

第二は、

embedding retriever自体の限界

です。

今回retrieverの比較は行ったものの、retrieverのfine-tuningや高度な改善までは行っていません。最終性能がretriever failureにどれほど影響されるかも十分評価できていません。  PRISM Patient Records Interpret...

第三は、

ground truthそのものが不安定

なことです。

annotator間でかなり判断が違い、「patient recordに十分な情報があるか」を判断するだけでもvariationが大きかったとしています。  PRISM Patient Records Interpret...

34. この論文で特に注意すべきN/A問題

これは著者のlimitations以上に重要だと思います。

この論文ではN/Aが、

1. 情報不足
2. questionがnot applicable

の両方を意味します。  PRISM Patient Records Interpret...

しかしこの2つは本来まったく異なります。

例えば、

「HER2 statusの記載がない」

はepistemic uncertainty / missing informationです。

一方、

「男性patientに妊娠状態を問う」

ならnot applicableです。

これらを同じN/Aにし、さらにunknownについて

$$P(Yes) = P(No) = 0.5$$

としてBoolean marginalizationするのは強い仮定です。

PRISMの今後の発展としては、

$$A = \{Yes, No, Unknown, Not Applicable\}$$

の4-class以上に分ける方が理論的には自然です。

35. Ground truthにも本質的問題がある

この研究でtrial rankingのground truthは、

患者が実際にそのtrialへenrollしたか

です。

しかし、

$$\text{not enrolled} \neq \text{not eligible}$$

です。

patient preference、trial slot availability、geographic logistics、physician recommendation、competing trialなど多数の理由があります。

実際、先ほどの10例manual reviewで9例がeligibleだったこと自体がこれを証明しています。

 PRISM Patient Records Interpret...

したがってこの研究のranking metricは、

「真のeligibility ranking」

というより、

historical enrollmentをproxy labelとしたranking

です。

これは論文を読むうえで非常に重要な区別です。

36. Human benchmarkも過大解釈はできない

AbstractではOncoLLMが「qualified medical doctorsのperformanceに匹敵する」と強く表現されています。
 PRISM Patient Records Interpret...

しかし、

OncoLLM = 63%

doctor ≈ 70%

であり、human test setも109 questionsに限定されています。

さらにannotator agreementそのものが64~70%程度です。
 PRISM Patient Records Interpret...

したがって本論文から安全に言えるのは、

clinical trial criteriaに関するEHR QAという曖昧性の高い課題において、**domain-fine-tuned 14B model**が**human disagreement**の存在する**performance range**へ近づいた

までです。

「医師を代替できる」という結果ではありません。

37. 再現性にも制限がある

OncoLLMはsingle cancer centerのproprietary dataを使っています。

clinical training dataだけで5,790 patients以上あり、manually annotated question–chunk pairsも数千ありますが、privacy/commercial reasonsにより詳細は公開されていません。  PRISM Patient Records Interpret...

評価dataもre-identification riskのため公開不可です。

codeもpublic repositoryではなく、

corresponding authorへの**reasonable request**

となっています。  PRISM Patient Records Interpret...

したがって、

conceptual reproducibilityは比較的高いが、**exact experimental reproducibility**は低い

研究です。

38. Generalizability

OncoLLMは、

single cancer center + oncology

に特化しています。

Model Cardでもgeneralizability limitationとhuman validationの必要性を明記しています。またdirect patient care decisionsやlegal/regulatory decisionsをout-of-scopeとしています。  PRISM Patient Records Interpret...

したがって、この論文の結果から、

「一般内科、循環器、希少疾患などでも63%」

とは言えません。

39. 利益相反

これは臨床AI研究なので確認しておくべき点です。

複数の著者がTriomics employeesで、Yanshan WangはPfizerおよびTriomicsのconsultantであり、BonafideNLPのownership/equity interestがあります。  PRISM Patient Records Interpret...

研究はMedical College of Wisconsin IRB #00044894の承認を受けており、specific grantは受けていないとされています。  PRISM Patient Records Interpret...

40. この論文の本当の新規性

PRISMの新規性は「LLMをclinical trial matchingに使ったこと」だけではありません。TrialGPTなどが既に存在します。

より本質的なのは、

Complex trial criteria $\rightarrow$ atomic questions + Boolean graph

と、

Longitudinal EHR $\rightarrow$ criterion-specific semantic retrieval

を組み合わせ、

さらに、

criterion-level eligibility $\rightarrow$ clinical-importance-weighted ranking

まで一つのpipelineにしたことです。

さらにpatient $\rightarrow$ trialだけでなく、

$Patient \rightarrow Trials$

と

$Trial \rightarrow Patients$

の両方向を同じsystemで評価した点も著者らが大きなcontributionとして挙げています。

 PRISM Patient Records Interpret...

41. この論文を最も簡潔に数式化すると

PRISMは、

P, T

というpatient-trial pairについて直接

$LLM(P, T) \rightarrow eligible/not\ eligible$

とするモデルではありません。

実際には、

$T \xrightarrow{LLM} \{q_j, \mathcal{B}\}$

ここで $\mathcal{B}$ はBoolean structureです。

次にpatient notesを、

$N(P) \rightarrow \{c_1, \dots, c_m\}$

へchunk化し、

各questionについて、

$R(q_j, N(P)) = TopK(c_i)$

をsemantic retrievalします。

その結果をLLMに入れて、

$g(q_j, R(q_j, N)) \rightarrow \{Yes, No, NA\}$

を推定します。

最後に、

$C(a_1, \dots, a_j; \mathcal{B}) \rightarrow criterion_k$

としてcriterion-level resultへ戻し、

$$S(P, T) = F(\text{criterion}_1, \dots, \text{criterion}_K, \text{tier}_1, \dots, \text{tier}_K)$$

を計算して、

$$T_1 > T_2 > \dots$$

という trial ranking を得るシステムです。

42. この論文を読むうえで最も重要な3つのポイント

第一に、**clinical trial matching**を一回のLLM classificationにしなかったことです。複雑なcriteriaをatomic QAへ落としたことが精度・説明可能性の両方に寄与しています。

第二に、患者**record**全体を扱うが、全部をLLMへ直接入れるわけではないことです。semantic retrievalを介してcriteriaごとに必要な根拠を取り出しています。しかもretrieval後はchronological orderingを行います。

第三に、最終結果を単なるcriteria accuracyでは終わらせず、**clinical workflow**で意味のある**patient-trial ranking**まで評価したことです。

これらがPRISMをTrialGPT型の単純なLLM matchingから一段進めている部分です。

総合評価

この論文は、2024年前後のclinical trial matching研究の中では、**real-world longitudinal oncology EHR**を使い、**retrieval・eligibility reasoning・evidence citation・ranking**を一つのpipelineとして評価した点でかなり重要な研究です。

一方で、「OncoLLMが医師レベル」「真のTop-3 accuracy ≈95%」という部分は、評価サンプル数やground truthの性質を考えると慎重に解釈する必要があります。また最大の研究課題は、**N/A / missing information**の扱い、**historical enrollment**をground truthにする問題、**retriever error**、**structured data**欠落、**single-center generalizability**、**proprietary training data**による再現性です。

特に方法論的には、この論文は「患者情報をそのまま一つのLLMに入れる」方式よりも、

- ① **criteria decomposition**
- ② **criterion-specific retrieval**
- ③ **criterion-specific reasoning**
- ④ **logical aggregation**
- ⑤ **weighted ensemble/scoring**

という設計を強く支持する研究と読むことができます。

なお、本文ではSupplementary Note 1–11等が多数参照されていますが、今回添付されているPDFは12ページのmain articleであり、**Supplementary Information**本体は含まれていません。したがって、chunking ablation、retriever比較、full prompt、13 conceptの完全なtier定義、追加サンプルなどについては、本文に記載された結果までは確認しましたが、Supplementaryの詳細そのものまではこのファイルだけでは検証できません。Supplementary Informationの存在は本文末にも明記されています。

 PRISM Patient Records Interpret...

もしこの論文を研究設計に使うなら、次に最も有用なのは、**PRISM・TrialGPT・TrialLlama・MIMIC-IV-Ext-Apixaban**系研究を「入力単位、**chunking、embedding/retriever、LLM、criteria decomposition、出力、ground truth、評価指標**」の同一フォーマットで横並び比較することです。これを見ると、PRISMが既存研究のどこを改善し、まだ何が未解決なのかがかなり明確になります。

情報源

   ... |  PDF に変換

