

言語モデルの地図：確率分布と 情報幾何による類似性の可視化



下平英寿
京都大学情報学研究科

NLPコロキウム 2025/08/27

言語モデルの地図：確率分布と情報幾何による類似性の可視化

NLP コロキウム

2025/08/27 (Wed) 12:00 (JST)

下平英寿 / Hidetoshi Shimodaira (京都大学)

京都大学大学院情報学研究科教授。1995年東京大学大学院工学系研究科計数工学専攻博士課程修了。統計数理研究所助手，東京工業大学准教授，大阪大学教授等を経て，2017年より現職。理化学研究所革新知能統合研究センター客員研究員を兼任。

ACL 2025でOutstanding Paper Awardを受賞した論文「Mapping 1,000+ Language Models via the Log-Likelihood Vector」に関連する話題を紹介します。本研究では，対数尤度ベクトルを用いて1,000を超える言語モデルを確率分布空間にマッピングし，情報幾何の枠組みのもとでそのテキスト生成の特性をKLダイバージェンスにより定量化しました。一般に，生成AIをテキストや画像といった多様なコンテンツを出力する確率分布とみなすと，このようなマッピングによりモデル間の類似性を精密に測定でき，性能予測や学習過程の分析に応用できます。高性能な言語モデルのオープンソース化が進み，利用者がモデルを個別に調整する時代が近い将来到来すれば，本研究のような多数のモデルの特性を体系的に把握するための評価技術の重要性は一層高まると考えられます。

https://nlp-colloquium-jp.github.io/schedule/2025-08-27_hidetoshi_shimodaira/

Mapping 1,000+ Language Models via the Log-Likelihood Vector

The 63rd Annual Meeting of the Association for Computational Linguistics (ACL 2025)

Mapping 1,000+ Language Models via the Log-Likelihood Vector

Momose Oyama^{1,2} Hiroaki Yamagiwa¹ Yusuke Takase¹ Hidetoshi Shimodaira^{1,2}
¹Kyoto University ²RIKEN
oyama.momose@sys.i.kyoto-u.ac.jp, h.yamagiwa@i.kyoto-u.ac.jp,
y.takase@sys.i.kyoto-u.ac.jp, shimo@i.kyoto-u.ac.jp

Abstract

To compare autoregressive language models at scale, we propose using log-likelihood vectors computed on a predefined text set as model features. This approach has a solid theoretical basis: when treated as model coordinates, their squared Euclidean distance approximates the Kullback-Leibler divergence of text-generation probabilities. Our method is highly scalable, with computational cost growing linearly in both the number of models and text samples, and is easy to implement as the required features are derived from cross-entropy loss. Applying this method to over 1,000 language models, we constructed a “model map,” providing a new perspective on large-scale model analysis.

1 Introduction


Language models have been evolving rapidly, and their community has expanded significantly. To understand this landscape and its future directions, it is essential to systematically analyze model similarity and positioning based on language modeling principles. On the Hugging Face Hub, models are categorized by name and attributes, while other studies assess similarity based on outputs (Yax et al., 2025) or activations (Zhou et al., 2025). Leaderboards (Beeching et al., 2023; Fourier et al., 2024; Chiang et al., 2024) are commonly used to assess model standings.

Since language models are probability models, we propose representing each model using coordinates that capture the geometric structure of the space of probability distributions. Concretely, we define a language model’s coordinates as its log-likelihood vector across a large collection of texts. Figure 1 shows a model map obtained through dimensionality reduction applied to the coordinates

Our code and data are available at <https://github.com/shino-lab/modelmap>.

32983

Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), pages 32983–33038
July 27 - August 1, 2025 ©2025 Association for Computational Linguistics



Momose Oyama
Hiroaki Yamagiwa
Yusuke Takase
Hidetoshi Shimodaira



Outstanding Paper Award

ACL 2025
VIENNA


<https://aclanthology.org/2025.acl-long.1584/>

モデル地図：対数尤度ベクトルでモデル座標を計算

Momose Oyama, Hiroaki Yamagiwa, Yusuke Takase, Hidetoshi Shimodaira (arXiv:2502.16173, ACL2025 main), Mapping 1,000+ Language Models via the Log-Likelihood Vector

$\{p_1, \dots, p_{1018}\}$ Hugging FaceのOpen LLM Leaderboard v1からダウンロード数上位の1000個のモデル + DeepSeek18個
 $D = (x_1, x_2, \dots, x_N)$ Pileコーパスからサンプリングしたテキストチャンクの集合、 $N=10,000$, 各1024バイト
 $\ell_i(x) = \log p_i(x)$ テキスト x におけるモデル p_i の対数尤度

➡ 言語モデル p_i の対数尤度ベクトル: $\ell_i = (\log p_i(x_1), \dots, \log p_i(x_N)) \in \mathbb{R}^N$



- 生成確率が類似のモデルが近くに配置される
- KLダイバージェンスで定量化される

言語モデルでKLダイバージェンスを計算してみた

Momose Oyama, Hiroaki Yamagiwa, Yusuke Takase, Hidetoshi Shimodaira (arXiv:2502.16173, ACL2025 main), Mapping 1,000+ Language Models via the Log-Likelihood Vector

対数尤度ベクトルの中心化 $\xi_{is} := \ell_i(x_s) - \bar{\ell}_i$


対数尤度の差の分散 $\|\xi_i - \xi_j\|^2 / N \approx 2 \text{KL}(p_i, p_j)$

meta-llama/Meta-Llama-3-8B	KL [bpb]	google/codegemma-2b	KL [bpb]	deepseek-ai/deepseek-llm-7b-base	KL [bpb]
Undi95/Meta-Llama-3-8B-hf	4.56e-06	deepseek-ai/deepseek-coder-1.3b-instruct	2.46	deepseek-ai/deepseek-moe-16b-base	0.194
dfurman/Llama-3-8B-Orpo-v0.1	0.0104	bigcode/starcoderbase-1b	2.69	deepseek-ai/deepseek-llm-7b-chat	0.364
migtissera/Tess-2.0-Llama-3-8B	0.0428	deepseek-ai/deepseek-coder-1.3b-base	3.14	deepseek-ai/deepseek-moe-16b-chat	0.368
freewheelin/free-llama3-dpo-v0.2	0.101	bigcode/gpt_bigcode-santacoder	3.92	deepseek-ai/DeepSeek-V2-Lite	0.455
jondurbin/bagel-8b-v1.0	0.164	deepseek-ai/deepseek-coder-6.7b-instruct	3.97	deepseek-ai/ESFT-vanilla-lite	0.456
migtissera/Llama-3-8B-Synthia-v3.5	0.190	Qwen/CodeQwen1.5-7B-Chat	4.09	deepseek-ai/DeepSeek-V2-Lite-Chat	0.868
nvidia/Llama3-ChatQA-1.5-8B	0.191	NTQAI/Nxcode-CQ-7B-orpo	4.11	mistralai/Mistral-7B-Instruct-v0.1	1.356
ruslanmv/Medical-Llama3-8B	0.206	Salesforce/codegen-6B-multi	4.24	statking/zephyr-7b-sft-full-orpo	1.616
FairMind/Llama-3-8B-4bit-UltraChat-Ita	0.296	bigcode/starcoderbase-7b	4.44	Severian/ANIMA-Phi-Neptune-Mistral-7B	1.692
NousResearch/Hermes-2-Theta-Llama-3-8B	0.330	deepseek-ai/deepseek-coder-6.7b-base	4.87	sethuyer/Medichat-Llama3-8B	1.718

単位 : bits / byte

言語モデルでKLダイバージェンスを計算してみた

Momose Oyama, Hiroaki Yamagiwa, Yusuke Takase, Hidetoshi Shimodaira (arXiv:2502.16173, ACL2025 main), Mapping 1,000+ Language Models via the Log-Likelihood Vector



博士2年（1993ころ）、統計的モデル選択のふたつのネタ

統計数理 (1993)
第41巻 第2号 131-147

モデルの信頼集合と地図によるモデル探索

東京大学* 下 平 英 寿

(1993年11月 受付)

1. はじめに

AICに基づくモデル比較は、広く応用され成果をあげている。その中でも代表的な、AIC最小化法によるモデル選択は、候補となるモデルについてAICの値を計算し、その値を最小にするモデルをひとつ選ぶものである。しかしモデル探索の初期の段階では、AICを比較的小さくするモデルを複数選ぶ方がよい。実際、AICの第1項に相当する対数尤度は大きな分散をもつので、データ数に対してモデルの候補の数が多い場合には、AIC最小のモデルがその他のモデルに対して有意に良いといえなくなる。すなわち、AICの差が、その標準誤差に対して有意に大きくなければ、モデル選択は信頼できないものとなる。

本稿ではAICの代わりに、より精密な、竹内(1976)によるTICを用いる。これについて2章で述べる。3章では、AICの差の分散について調べる。4章では、その分散の推定量を用い、多重比較の方法を利用して、モデルの信頼集合を構成する。モデル信頼集合とは、候補となるモデルのうち一番良いものを、与えられた有意水準で含むような集合である。信頼集合の計算結果は、各モデルの P -値として与えられる。ただし、モデルの P -値とは、そのモデルが信頼集合に含まれるような有意水準の最大値である。実際の P -値の計算では近似を行なっているので、得られる結果は名目上の P -値である。

ここで行なおうとしているモデル選択では、まず、候補となる各モデルの P -値を計算する。そしてモデルを P -値の大きい順に並べ、与えられた有意水準以上の P -値をもつモデルを、モデル信頼集合の要素として選ぶ。モデルの候補の数に比べてデータ数が少ない場合、モデル信頼集合は大きくなる傾向がある。これは、データ数が十分でない場合、AICの値はあまり信頼できなくなることに対応する。このような場合、モデル信頼集合にどのような傾向のモデルが含まれているかを調べるのが重要になる。

5章では、モデル信頼集合の傾向を調べるために、モデル間の距離を定義し、モデル地図を描く。モデル間距離としては、AICの差の分散(の推定値)の平方根を用いる。これは真の分布に依存して変わるので、「その真の分布から見た」地図(の推定)が描かれることになる。この地図を見ることによって、各モデル毎に推定された分布の、確率分布の空間における相対的な位置関係を把握できる。これにより、真の分布がどのようなモデルに近いのかといったことについて、示唆を得ることができる。6章では、重回帰分析の変数選択問題について、いくつかの数値例をあげる。

* 計数工学科: 〒113 文京区本郷7-3-1.

ネタ1：モデル信頼集合

4. モデル信頼集合

モデルの候補を $N=\{1, 2, \dots, l\}$ とする。この l 個のモデルのTICとriskを $\text{TIC}_1, \text{TIC}_2, \dots, \text{TIC}_l$ と $\text{risk}_1, \text{risk}_2, \dots, \text{risk}_l$ とする。riskを小さい順に並べたものを $\text{risk}_{[1]} \leq \text{risk}_{[2]} \leq \dots \leq \text{risk}_{[l]}$ と書く。riskを一番小さくするモデル $[1]$ を見つけ出すことがここでの目的である。本章は、Shimodaira (1993b) にそって述べる。

risk最小のモデルが複数あることを考えて、 $\mathcal{S}^* = \{i \in N : \text{risk}_i = \text{risk}_{[1]}\}$ とおく。観測データから構成するモデルの信頼集合を $\mathcal{S} \subset N$ と書く。一番良いモデルを与えられた有意水準で含み、かつなるべく小さくなるように、 $\mathcal{S}$ を決めたい。Tukey流の多重比較の方法に従えば、有意水準 α は次のように定義される。 $\Pr\{\mathcal{S}^* \subset \mathcal{S}\} \geq 1 - \alpha$ (Hochberg and Tamhane (1987)). これとは別に、Gupta流のsubset selectionの方法に従えば、有意水準は次のように定義される。各 $k \in \mathcal{S}^*$ について $\Pr\{k \in \mathcal{S}\} \geq 1 - \alpha$ (Gupta and Panchapakesan (1979)). 本稿ではこの二通

ネタ2：モデル地図

5. モデル地図

データ数に対してモデルの候補の数が多い場合、モデル信頼集合は大きくなる傾向がある。先験知識にしたがって、モデルの候補をなるべく絞っておくべきなのはいうまでもないのだが、実際の応用では、候補の数が非常に多くなる場合も少なくない。このようにして信頼集合が大きくなってしまった場合、どのような傾向のモデルが選ばれているのかを調べるのが重要になる。これにより、新たにデータをとるための実験の計画を考えたり、モデルの候補のクラスを考え直すこともできるだろう。このためのひとつの手段として、本章では「モデル地図」について

ネタ1：モデル信頼集合

めっちゃバズった

統計的モデル選択におけるリサンプリングによる統計的信頼度の研究

下平 (1993)をきっかけにAIC等によるモデル選択のバラツキを考慮した信頼度の手法と理論を統計学の専門誌 ([Annals of the Institute of Statistical Mathematics](#), [Journal of Statistical Planning and Inference](#), [Annals of Statistics](#)) で発表し, 分子進化学[1-3], 遺伝子発現解析[4]の階層クラスタリング等で標準的に利用される手法となった

[1] H. Shimodaira and M. Hasegawa. Multiple comparisons of log-likelihoods with applications to phylogenetic inference, *Molecular Biology and Evolution*, 16, 1114-1116, 1999. 【被引用数 4664】


[2] H. Shimodaira and M. Hasegawa. CONSEL: for assessing the confidence of phylogenetic tree selection, *Bioinformatics*, 17, 1246-1247, 2001. 【被引用数 2269】

[3] H. Shimodaira. An approximately unbiased test of phylogenetic tree selection, *Systematic Biology*, 51, 492-508, 2002. 【被引用数 2971】

[4] R. Suzuki, H. Shimodaira. pvclust: an R package for assessing the uncertainty in hierarchical clustering, *Bioinformatics*, 22, 1540-1542, 2006. 【被引用数 2722】

系統樹の確率を計算する統計手法として知られる

- Shimodaira-Hasegawa test (SH test)
- Multiscale Bootstrap Resampling (AU test)



このネタは今日はトークしません

助手のころのネタ：共変量シフト (Covariate Shift)

これも、めっちゃバズった

学習時とテスト時でデータ分布が異なる設定（共変量シフト）の統計理論

この定式化とモデル選択の理論を与え[5], AI分野で「転移学習」の標準設定となる

[5] H. Shimodaira. Improving predictive inference under covariate shift by weighting the log-likelihood function, *Journal of Statistical Planning and Inference*, 90, 227-244, 2000. 【被引用数 2530】

- 学習時とテスト時で分布が変化する設定の考案
- 確率密度比で対数尤度を重み付けする手法の提案
- Covariate Shiftという単語をつくった

その後の「〇〇シフト」という設定の元ネタ

このネタも今日はトークしません

230

H. Shimodaira / *Journal of Statistical Planning and Inference* 90 (2000) 227-244




Fig. 1. Fitting of polynomial regression with degree $d=1$. (a) Samples (x_i, y_i) of size $n=100$ are generated from $q(y|x)q_0(x)$ and plotted as circles, where the underlying true curve is indicated by the thin dotted line. The solid line is obtained by OLS, and the dotted line is WLS with weight $q_1(x)/q_0(x)$. (b) Samples of $n=100$ are generated from $q(y|x)q_1(x)$, and the regression line is obtained by OLS.

ネタ2：モデル地図【今日のトークの話題】

まったく売れなかった

Classics: Early Papers on Model Maps

<https://github.com/shimo-lab/modelmap/tree/main/classics>

回帰分析の変数選択




図7. データセット BABY のモデル地図.





図8. データセット BABY のモデル地図 (模式図).

図9. データセット BABY のクラスタ分析.

下平 (1993)




回帰分析の変数選択

Shimodaira and Cao (1998), Shimodaira (2001)


分子進化系統樹の検定

分子進化系統樹のMCMC



Shimodaira and Hasegawa (2005)

分子進化系統樹の検定



Shimodaira and Terada (2019)

モデルの個性（特性）を定量化したい


「確率分布の空間を見る」手法の提案

生成AIがバズってるいまこそ、役立つのでは???



背景：大量の言語モデルが存在

- Hugging Face ⁽¹⁾ では約**27万**の言語モデルが公開されている ⁽²⁾.



(1) <https://huggingface.co/>. 画像の URL は https://huggingface.co/models?pipeline_tag=text-generation&sort=likes.

(2) 2025/08/27 現在. 言語モデルとして text-generation のタグで検索. likes でソート. ※ タグをつけていない言語モデルも多くあると思われる.

モチベーション：言語モデルの類似関係

類似関係の活用例

- 学習データが似たモデル同士の類似度や性能を調べ、モデル開発の指針を得られる.
- ファインチューニング後のモデルと元のモデルを比較し、学習による変化を把握する.
- 自分のモデルが他者に不正利用されているかを検出する.

言語モデルの類似関係を調べた既存研究

- [Zhu+2025] はパラメータの類似度を測定.
- [Yax+2025] は入力文の応答から距離を計算.
- [Zhou+2025] は中間表現の類似度を測定.
- [Zhuang+2025] は問題を解けるかどうかで埋め込む.

より客観的にモデルの個性（特性）を定量化したい

Zhu et al. Independence Tests for Language Models. Preprint 2025.

Yax et al. PhyloLM: Inferring the phylogeny of large language models and predicting their performances in benchmarks. ICLR 2025.

Zhou et al. Linguistic Minimal Pairs Elicit Linguistic Similarity in Large Language Models. COLING 2025.

Zhuang et al. EmbedLLM: Learning Compact Representations of Large Language Models. ICLR 2025.

言語モデルと対数尤度

テキスト x はトークン列、 y はトークン: $x = (y_1, \dots, y_n)$

$p_i(x)$ 言語モデル p_i がテキスト x を出力する確率

$\ell_i(x) = \log p_i(x)$ 対数尤度



この確率分布が言語モデルの出力特性に関するすべての情報を持っている

自己回帰型言語モデル（通常はTransformerで実装）

$$y_t \sim p_i(y_t \mid y_0, \dots, y_{t-1}), \quad t = 1, \dots, n.$$

$$p_i(x) = \prod_{t=1}^n p_i(y_t \mid y_0, \dots, y_{t-1})$$

$$\ell_i(x) = \sum_{t=1}^n \log p_i(y_t \mid y_0, \dots, y_{t-1})$$

パープレキシティ: $\exp(-\ell_i(x)/n)$

クロスエントロピーロス: $-\ell_i(x)$

モデル間の類似性：Kullback-Leibler divergence

$$\text{KL}(p_i, p_j) = \sum_{x \in \mathcal{X}} p_i(x) \log \frac{p_i(x)}{p_j(x)}$$

和を取る範囲は、すべての文字列
(もちろん、計算できません)

$$= \mathbb{E}_{x \sim p_i} (\ell_i(x) - \ell_j(x))$$

テキストxを p_i から生成して平均
(これは計算できる、通常の実装方法)

2つのモデル間の距離（の2乗）のようなもの

$$\text{KL}(p_i, p_i) = 0$$

非対称だけど、モデルが近いときは、ほぼ対称

$$\text{KL}(p_i, p_j) \approx \text{KL}(p_j, p_i)$$

p_i からxを生成したときに、 p_j を信じて符号化したときの、平均符号長の p_i からの増分

$$\text{KL}(p_i, p_j) [\text{bit}] = \sum_{x \in \mathcal{X}} p_i(x) (-\log_2 p_j(x)) - \sum_{x \in \mathcal{X}} p_i(x) (-\log_2 p_i(x)) \geq 0$$

エントロピー

参考：最尤推定 Maximum Likelihood Estimate

$D = (x_1, x_2, \dots, x_N)$ テキストの集合、事前学習に使われる
Pileデータセット：825GB、3000億トークン

$\max_{\theta} \sum_{x \in D} \log p(x|\theta)$ は、KLダイバージェンスの最小化、ともいえる

$$x_1, x_2, \dots, x_N \sim p_0$$

$$\text{KL}(p_0, p(\theta)) = \sum_{x \in \mathcal{X}} p_0(x) \log p_0(x) - \sum_{x \in \mathcal{X}} p_0(x) \log p(x|\theta)$$

$$= \sum_{x \in \mathcal{X}} p_0(x) \log p_0(x) - \mathbb{E}_{x \sim p_0} (\log p(x|\theta))$$

$$\approx \sum_{x \in \mathcal{X}} p_0(x) \log p_0(x) - \frac{1}{N} \sum_{x \in D} \log p(x|\theta)$$

KLダイバージェンスを期待値ではなく分散として評価する

定理：下平 (1993), Shimodaira and Cao (1998), Shimodaira (2001), Oyama et al. (2025)

$$2 \text{KL}(p_i, p_j) \approx \text{Var}_{x \sim p_0} (\ell_i(x) - \ell_j(x)) \quad \text{仮定: } p_0, p_i, p_j \text{ は互いに十分近い}$$

この式のすごいところは、テキスト生成の分布 p_0 が多少変化しても安定で、たとえば $p_0=p_i$ でも $p_0=p_j$ でもOK.

一方、通常のKLの定義式は分布の変化に敏感で、テキスト生成の分布を p_i から p_j に変更すると符号が反転してしまう。つまり不安定で使いにくい。

$$\begin{aligned} \text{KL}(p_i, p_j) &= \mathbb{E}_{x \sim p_i} (\ell_i(x) - \ell_j(x)) \\ -\text{KL}(p_j, p_i) &= \mathbb{E}_{x \sim p_j} (\ell_i(x) - \ell_j(x)) \end{aligned}$$

対数尤度ベクトルは、確率分布の空間へのモデルの「埋め込み」

$x_1, x_2, \dots, x_N \sim p_0$ テキストの集合、ここではN=10,000, 各1024バイト

$\ell_i = (\log p_i(x_1), \dots, \log p_i(x_N))$ 対数尤度ベクトル

$2 \text{KL}(p_i, p_j) \approx \text{Var}_{x \sim p_0} (\ell_i(x) - \ell_j(x))$ p_0, p_i, p_j は互いに十分近いと仮定

$$\approx \frac{1}{N} \sum_{s=1}^N (\xi_{is} - \xi_{js})^2$$

【中心化】 $\xi_{is} := \ell_i(x_s) - \bar{\ell}_i$

$$= \|\boldsymbol{\xi}_i - \boldsymbol{\xi}_j\|^2 / N$$

ユークリッド距離の2乗がKLになる

$$= \|\mathbf{q}_i - \mathbf{q}_j\|^2 / N$$


【二重中心化】 $\mathbf{q}_i = \boldsymbol{\xi}_i - \bar{\boldsymbol{\xi}}$
(成分の解釈性向上のため)

対数尤度ベクトルのヒートマップ

Momose Oyama, Hiroaki Yamagiwa, Yusuke Takase, Hidetoshi Shimodaira (arXiv:2502.16173, ACL2025 main), Mapping 1,000+ Language Models via the Log-Likelihood Vector

1,018言語モデル x 10,000テキスト の対数尤度行列

Log-Likelihood Matrix Q (Double Centered)




遺伝子発現解析でよくやるheatmap (two-way hierarchical clustering) と同じ

重みの線形結合でモデルマージして6x6=36個のモデルを作成

Momose Oyama, Hiroaki Yamagiwa, Yusuke Takase, Hidetoshi Shimodaira (arXiv:2502.16173, ACL2025 main), Mapping 1,000+ Language Models via the Log-Likelihood Vector


重み空間（70億次元）のPCA



問題点1：情報幾何の観点ではFisher情報行列で距離の歪みを補正して正規化すべき

問題点2：ニューラルネットは中間層のユニット入れ替えで不変だから、そもそも重みの直接比較は厳しく、ニューラルネットの出力で比較すべき



対数尤度空間（10,000次元）のPCA



2つの問題点を同時に解決： ユークリッド空間として扱えばKLの近似式が成り立つ

事前に指定したテキストを用いる：**言語モデルに「生成させない」ことで高速化**

Amari (1985)



確率分布の空間
(対数尤度空間に相当)

パラメータ空間

$$\begin{aligned} & \text{KL}(p(\theta), p(\theta')) \\ & \approx \frac{1}{2}(\theta' - \theta)^\top G(\theta)(\theta' - \theta) \end{aligned}$$

証明：モデルをマージする指数型分布族を定義してテイラー展開

下平 (1993)

定理 2. $D(q, p)$ は K-L 情報量とする. $D(q, p_1^*)$ と $D(q, p_2^*)$ が十分に小さい時,

$$V\{e^*\} = J + O(\|D(q, p_1^*)^{1/2}, D(q, p_2^*)^{1/2}\|^3)$$

ただし, $J = D(p_1^*, p_2^*) + D(p_2^*, p_1^*)$ とする.

このように, $D(q, p)$ として K-L 情報量を用いて, 3 つの分布 p_1^*, p_2^*, q が十分に近いと仮定できる時は, $V\{e^*\} \approx D(p_1^*, p_2^*) + D(p_2^*, p_1^*)$ と近似できる. この解釈に基づいて, 5 章では, モデル地図を構成する.

定理 2 の証明. 次のように $\alpha = (\alpha_1, \alpha_2)$ でパラメトライズして, $p(x | \alpha)$ をつくる.

$$\log p(x | \alpha) = (1 - \alpha_1 - \alpha_2) \log q(x) + \alpha_1 \log p_1^*(x) + \alpha_2 \log p_2^*(x) - c(\alpha)$$

この時, $p_1^* = p(1, 0)$, $p_2^* = p(0, 1)$, $q = p(0, 0)$ である. さて, $\log p$ を l で表し, $p \partial_i l = \partial_i p$ に注意すると,

$$l_\alpha = l_0 + \sum (\partial_i l_0) \alpha_i + O(\|\alpha\|^2), \quad p_\alpha = p_0(1 + \sum (\partial_i l_0) \alpha_i) + O(\|\alpha\|^2)$$

とかける. これより直ちに,

$$\begin{aligned} J(p_\alpha, p_\beta) &= D(p_\alpha, p_\beta) + D(p_\beta, p_\alpha) \\ &= \int (p_\alpha - p_\beta)(l_\alpha - l_\beta) dx \\ &= \int p_0 (\sum \partial_i l_0 (\alpha_i - \beta_i))^2 dx + O(\|\alpha, \beta\|^3) \\ &= \sum \sum g_{ij} (\alpha_i - \beta_i) (\alpha_j - \beta_j) + O(\|\alpha, \beta\|^3) \end{aligned}$$

ただし, $g_{ij} = \int p_0 (\partial_i l_0) (\partial_j l_0) dx$ とおく. ところで, $E\{\partial_i l_0\} = \int p_0 \partial_i l_0 dx = 0$ に注意すると,

$$\begin{aligned} V\{l_\alpha - l_\beta\} &= \int p_0 (l_\alpha - l_\beta)^2 dx + O(\|\alpha, \beta\|^4) \\ &= \int p_0 (\sum \partial_i l_0 (\alpha_i - \beta_i))^2 dx + O(\|\alpha, \beta\|^3) \\ &= J(p_\alpha, p_\beta) + O(\|\alpha, \beta\|^3). \end{aligned}$$

最後に, $\alpha = (1, 0)$, $\beta = (0, 1)$ とおけば良い.

ちょ、あっさりしすぎ、、、

Oyama et al. (2025)

D.1 Exponential family of distributions

We first consider a model in the exponential family of distributions parameterized by a K -dimensional parameter $\theta \in \mathbb{R}^K$:

$$p(x; \theta) = p_0(x) \exp(\theta^\top b(x) - \psi(\theta)). \quad (7)$$

Here, the function $b(x) = (b_1(x), \dots, b_K(x))^\top$ will be defined later using the K models. The normalization constant is given by

$$Z(\theta) = \sum_{x \in \mathcal{X}} p_0(x) \exp(\theta^\top b(x)),$$

$$\psi(\theta) = \log Z(\theta),$$

which ensures that $\sum_{x \in \mathcal{X}} p(x; \theta) = 1$. For $\theta = 0$, where $0 = (0, \dots, 0)^\top$, we obtain

$$p(x; 0) = p_0(x).$$

To associate the K models with (7), we define $b(x)$. For a constant $\lambda > 0$, we set

$$\lambda b_i(x) := \ell_i(x) - \ell_0(x). \quad (8)$$

The constant λ is an order parameter introduced for theoretical convenience, and in our theoretical framework, we assume that $b_i(x)$ is of constant order and that λ is sufficiently small¹⁵. Thus, we essentially assume that $|\ell_i(x) - \ell_0(x)| = O_p(\lambda)$ is sufficiently small, implying that each model p_i provides a good approximation of the true generative model p_0 . In the proof of the main theorem, we consider the asymptotic theory as $\lambda \rightarrow 0$, retaining terms up to $O(\lambda^2)$ while ignoring those of $O(\lambda^3)$.

A one-hot vector is defined as $e_i = (0, \dots, 0, 1, 0, \dots, 0)^\top \in \mathbb{R}^K$ for $i = 1, \dots, K$, where only the i -th element is 1. Then, setting $\theta = \lambda e_i$ gives

$$p(x; \lambda e_i) = p_i(x). \quad (9)$$

Indeed, substituting (8) into (7) yields

$$p(x; \lambda e_i)$$

D.2 Properties of the exponential family of distributions

This section outlines some well-known basic properties of the exponential family of distributions, which have been established in the literature (Barndorff-Nielsen, 2014; Efron, 1978, 2022; Amari, 1982). We define the expectation and covariance matrix of $b(x)$ as follows:

$$\eta(\theta) := \mathbb{E}_{x \sim p(\theta)}(b(x)) = \sum_{x \in \mathcal{X}} b(x) p(x; \theta),$$

$$G(\theta) := \mathbb{E}_{x \sim p(\theta)}\{(b(x) - \eta(\theta))(b(x) - \eta(\theta))^\top\} = \text{Var}_{x \sim p(\theta)}(b(x)).$$

Here, the elements of $\eta(\theta)$ are expectations given by $\mathbb{E}_{x \sim p(\theta)}(b_i(x))$, and the elements of $G(\theta)$ are covariances given by $G_{ij}(\theta) = \text{Cov}_{x \sim p(\theta)}(b_i(x), b_j(x))$. These quantities can be expressed in terms of $\psi(\theta)$ as follows:

$$\eta(\theta) = \frac{\partial \psi(\theta)}{\partial \theta}, \quad (10)$$

$$G(\theta) = \frac{\partial^2 \psi(\theta)}{\partial \theta \partial \theta^\top}. \quad (11)$$

We now derive these two equations. First, from

$$\frac{\partial Z(\theta)}{\partial \theta} = \sum_{x \in \mathcal{X}} b(x) p_0(x) e^{\theta^\top b(x)},$$

we obtain


$$\begin{aligned} \frac{\partial \psi(\theta)}{\partial \theta} &= \frac{\partial \log Z}{\partial \theta} = \frac{1}{Z(\theta)} \frac{\partial Z}{\partial \theta} \\ &= \frac{1}{Z(\theta)} \sum_{x \in \mathcal{X}} b(x) p_0(x) e^{\theta^\top b(x)} \end{aligned}$$

指数型分布族の性質を利用して
今回は3ページくらい書いた


モデル地図：対数尤度ベクトルでモデル座標を計算

Momose Oyama, Hiroaki Yamagiwa, Yusuke Takase, Hidetoshi Shimodaira (arXiv:2502.16173, ACL2025 main), Mapping 1,000+ Language Models via the Log-Likelihood Vector



1,018言語モデル x 10,000テキスト の対数尤度行列




tSNEで2次元に可視化してモデル地図を作成



モデルタイプ (ベースモデル)




6-TaskMean



6種タスクの平均性能

Primary Task



得意なタスク (タスク性能で測定)


タスク名

- 総合学力
- 科学的推論
- 常識推論
- 代名詞解決
- 事実性
- 数学

モデルの個性 (属性や性能) の領域がクラスタとして見える

モデル地図：対数尤度ベクトルでモデル座標を計算（つづき）

Momose Oyama, Hiroaki Yamagiwa, Yusuke Takase, Hidetoshi Shimodaira (arXiv:2502.16173, ACL2025 main), Mapping 1,000+ Language Models via the Log-Likelihood Vector



Meta, Google, DeepSeek等の
コード関連のモデル達

Mistral派生モデル達


Llama2派生モデル達

モデルの個性（属性や性能）の領域がクラスタとして見える

モデル地図：対数尤度ベクトルでモデル座標を計算（つづき）

Momose Oyama, Hiroaki Yamagiwa, Yusuke Takase, Hidetoshi Shimodaira (arXiv:2502.16173, ACL2025採択), Mapping 1,000+ Language Models via the Log-Likelihood Vector


Primary Text Category



- DM Mathematics
- ArXiv
- PubMed Central
- PubMed Abstracts
- NIH ExPorter
- USPTO Backgrounds
- Github
- StackExchange
- Ubuntu IRC
- HackerNews
- Pile-CC
- Wikipedia (en)
- Gutenberg (PG-19)
- Enron Emails
- FreeLaw
- PhilPapers
- EuroParl

数学：数学関連の論文や議論を含む
論文プレプリント：物理・数学・コンピュータ科学など様々な学術分野の論文プレプリント
医学論文：医学・生物医学分野の査読済み論文を収録した論文データベース
医学アブストラクト：医学系論文の要旨のみを収録したデータベース
研究プロジェクト：米国国立衛生研究所(NIH)が支援する研究プロジェクトの概要
特許：米国特許庁(USPTO)に提出された特許の技術背景の説明
ソースコード：ソフトウェア開発におけるソースコードや技術文書
Q&Aサイト：プログラミング・数学・科学などの技術的なQ&Aサイトの内容
技術チャット：Ubuntu (Linux) のユーザー間でのリアルタイムな技術チャット
技術ニュース：テクノロジー分野を中心としたニュースおよびコミュニティ投稿
一般ウェブ：ウェブクロールから収集した一般的なウェブサイトのテキスト
百科事典：英語版ウィキペディアの記事全文
書籍：パブリックドメインの英語書籍を収録したプロジェクト・グーテンベルクのコレクション
メール：Enron社社員の電子メール記録（実際のメール文書）
法律：米国の法律・判例などの法的文書
哲学：哲学分野の研究論文および文献目録データベース
議会記録：欧州議会での議論・演説の記録（翻訳テキストを含む）

t-SNE Visualization of Text Embeddings





- Text Category
- DM Mathematics
 - ArXiv
 - PubMed Central
 - PubMed Abstracts
 - NIH ExPorter
 - USPTO Backgrounds
 - Github
 - StackExchange
 - Ubuntu IRC
 - HackerNews
 - Pile-CC
 - Wikipedia (en)
 - Gutenberg (PG-19)
 - Enron Emails
 - FreeLaw
 - PhilPapers
 - EuroParl

モデルの個性（属性や性能）の領域がクラスタとして見える

モデル地図：対数尤度ベクトルでモデル座標を計算（つづき）



Momose Oyama, Hiroaki Yamagiwa, Yusuke Takase, Hidetoshi Shimodaira (arXiv:2502.16173, ACL2025採択), Mapping 1,000+ Language Models via the Log-Likelihood Vector



モデルの個性（属性や性能）の領域がクラスタとして見える

モデル地図：対数尤度ベクトルでモデル座標を計算（つづき）


Momose Oyama, Hiroaki Yamagiwa, Yusuke Takase, Hidetoshi Shimodaira (arXiv:2502.16173, ACL2025採択), Mapping 1,000+ Language Models via the Log-Likelihood Vector




モデルの個性（属性や性能）の領域がクラスタとして見える

モデル地図上でデータ漏洩の検出

尤度計算に用いたデータ (the Pile) を事前学習で使うモデル



テキストデータの尤度に対してベンチマークの性能が低いモデル



KLの値のめやす (単位は bits/byte)

Ryo Kishino, Yusuke Takase, Momose Oyama, Hiroaki Yamagiwa, Hidetoshi Shimodaira (arXiv:2505.15353) Revealing Language Model Trajectories via Kullback-Leibler Divergence

	between checkpoints			between seeds	between model sizes			
	10k→11k	50k→51k	100k→101k	avg.	1B	1.4B	2.8B	6.9B
410M	0.069 (±0.0011)	0.053 (±0.0010)	0.023 (±0.00042)	0.11 (± 0.0024)	0.28 (±0.010)	0.52 (±0.018)	1.0 (±0.036)	1.7 (±0.060)

(a) KL divergence for Pythia 410M, measured between checkpoints saved during pretraining, different random seeds, and different model sizes. For the inter-size comparison, the final checkpoints were used. See Section 3 for details.

Type (#pair)	Pair	Median	Mean	SD
mistral (25)	fine-tuning	0.32	0.37	0.32
	random	0.79	0.74	0.39
llama-3 (20)	fine-tuning	0.20	0.67	0.80
	random	0.66	0.87	0.66
all (66)	fine-tuning	0.40	1.5	3.6
	random	2.1	5.0	9.5

(b) Summary statistics (median, mean, SD) of KL divergence between fine-tuned and base models, and between random model pairs. See Section 4 for details.

Model	1→2	16→17	31→32
Llama-2-7b-hf	0.61 (± 0.013)	1.6 (± 0.063)	1.3 (± 0.10)
Meta-Llama-3-8B	4.0 (± 0.075)	22 (± 0.78)	1.7 (± 0.037)
Mistral-7B-v0.3	2.4 (± 0.10)	5.7 (± 0.12)	8.6 (± 0.54)


(c) KL divergence between adjacent layers within models, measured using the logit lens. See Section 5 for details.

Table 1: KL divergence in bits per byte between language models under various conditions. Values in parentheses represent standard errors. See Appendix C for the formula used to compute the standard errors.


モデル軌道：事前学習時のチェックポイントをモデル地図で分析

Ryo Kishino, Yusuke Takase, Momose Oyama, Hiroaki Yamagiwa, Hidetoshi Shimodaira (arXiv:2505.15353) Revealing Language Model Trajectories via Kullback-Leibler Divergence


Pythia modelsの事前学習チェックポイント



$\text{distance}^2 \propto \text{step}^c$ **べき則が観察された**
cは拡散指数、 $H=c/2$ はHurst指数




異常拡散の発見




注意：「軌道の振動」はtsneによるアーティファクトと気付いた（投稿論文はwithdrawして改訂準備中）

モデル軌道：言語モデルの内部をモデル地図で分析

Ryo Kishino, Yusuke Takase, Momose Oyama, Hiroaki Yamagiwa, Hidetoshi Shimodaira (arXiv:2505.15353) Revealing Language Model Trajectories via Kullback-Leibler Divergence



- Transformer内部の層から直接トークン確率を出力させる手法 (logit-lens) を用いた
- 各層を「モデル」とみなす
- 浅い層から深い層への変化を「モデル軌道」とした



Remarks

- 対数尤度ベクトルをモデルの特徴量とするとモデルの特性がよく反映される
- 中心化した対数尤度ベクトルをモデル座標とすればユークリッド距離の2乗がKLになる
- モデル開発において性能予測や学習過程の分析に応用できる
- プロンプトを設定することで条件付き分布間のKLも測定できる※
- 多数の生成モデルの「個性」を体系的に把握するための評価技術
- 高性能な言語モデルのオープンソース化が進み利用者がモデルを個別に調整する状況で役に立つかも
- テキスト集合の選定に比較的口バストだが、実際には結果は変わる．特定分野のテキストを利用することは「射影」に相当し、その分野の解像度が高まる
- テキスト毎の「対数尤度の分散」を利用して効率的にテキストを選択する手法
 - Oyama et al. Likelihood Variance as Text Importance for Resampling Texts to Map Language Models (arXiv:2505.15428)
- ここでは自己回帰型の言語モデルでTransformer実装にアクセスできるwhitebox設定
 - 確率を直接観測できないblackbox設定でも、テキスト生成を媒介してモデル地図つくれる※
 - 拡散モデルのwhitebox設定はかなり近似になるかも※

※準備中